

NIPT 最优检测时点与女胎异常判定的建模研究

摘要

无创产前检测 (NIPT) 是通过检测母体血浆中的胎儿游离 DNA 来判定染色体异常的重要技术。然而, 目前临床多依赖经验分组, 忽视个体特征与检测误差, 易致检测不准。因此, 求解不同 BMI 男胎孕妇的 NIPT 最优检测时点、探究女胎异常判定方法, 是本文亟待解决的核心问题。

针对问题一, 基于题目给定的数据信息, 进行异常值剔除、多次检测样本合并等预处理。首先确定孕周和 BMI 为主要自变量, 考虑 Y 染色体浓度、孕周与 BMI 三者相关性, 构建 Beta 回归广义加性混合 Beta-GAMM 模型, 明确孕周与 BMI 对 Y 染色体浓度的函数关系。基于平滑曲线和交互等高线图, 得到浓度随孕周增加而上升、随 BMI 增大而下降的趋势。其次, 在广义可加模型的基础上通过残差极大似然值筛选模型优劣, 对变量显著性进行检验。分析偏效应函数, 发现孕周增加使浓度在 20 周升至约 6%, BMI 每增加 5 单位浓度下降约 0.5%, 呈现促进与抑制的相反作用。

针对问题二, BMI 被确认为影响男胎 Y 染色体最早达标时间的核心解释变量, 据此将孕妇分为五个区间。结合条件阈值 4%, 建立基于条件均值与下界判定的方法, 利用非参数回归得到浓度均值 $\mu(G, BMI)$, 并结合交叉验证残差估计标准差 σ , 定义下界 $L = \mu - 1.645\sigma$, 当 $L \geq 0.04$ 时的取值判定为个体的最早可靠孕周 g^* 。另外, 以组内全部样本的 g^* 值构建覆盖率曲线 $C_k(t)$, 并设定目标比例 $p_0 = 0.80$, 取覆盖率首次超过目标的孕周作为推荐检测时点。最终低 BMI 组在 12-13 周即可达到 80% 覆盖率, 高 BMI 组需延后至 15-16 周。其中, 敏感性分析显示, 检测误差扩大时, 各组推荐时点整体推迟 1-2 周。

针对问题三, 首先在第二问的基础上增加孕妇年龄、身高和体重等个体特征, 结合交叉验证得到残差标准差 σ 与实验变异系数 CV , 构建孕周-BMI 风险最小化决策模型。对于约束条件, 模型设置统一测序口径区间, 分组数不超过六类, 且每组样本量不少于规定阈值。通过覆盖率曲线 $C_k(t)$ 计算各组在不同孕周下的达标比例, 并设计风险函数 $R_1(t)$ 与 $R_2(t_1, t_2)$, 在目标函数中引入时间延迟风险与检测失败损失, 并求解最优检测时点。基于风险曲线图, 高 BMI 且体重偏大的孕妇推荐检测时点整体延后至约 16 周, 同时考虑年龄和身高条件时, 检测时点呈现出更大的组间差异。最后, 使用孕周-BMI 风险最小化决策模型评估稳健性, 并在第二问基础上增加孕妇年龄、身高和体重等变量。结果表明, 在误差参数波动下推荐时点整体仅后移 1-2 周, 相比单一考虑 BMI 的情形更加可靠。

针对问题四, 由于女胎缺乏 Y 染色体, 无法直接判定是否异常, 以附件 AB 列所示的 13、18、21 号染色体非整倍体状态作为参考标签, 结合 X 染色体 Z 值、GC 含量、测序深度及 BMI 等多维特征, 并加入交互项和偏倚指标, 构建 EasyEnsemble 集成学习分类器。训练后, 对模型输出进行概率校准, 并引入共形预测方法设置双阈值机制, 分别控制漏诊率和误报率。基于混淆矩阵与 ROC 曲线, 发现该方法的召回率达到约 95%, 将误判率控制在约 15% 以下, 最终形成“正常—异常—灰区”的三类判定框架, 从而实现了对女胎异常的识别, 同时使用流程图表示完整的判定机制。

关键词: NIPT; Beta-GAMM 模型; 孕周-BMI 检测时点模型; 风险最小化决策模型; EasyEnsemble; 共形预测

一、问题重述

1.1 问题背景

NIPT 是一种基于母体血液样本检测胎儿染色体异常的非侵入性产前筛查技术。通过分析孕妇外周血中胎儿游离 DNA 片段，能够在孕早中期对常见染色体非整倍体进行有效筛查。检测的准确性依赖于胎儿 DNA 浓度，其中男胎的 Y 染色体浓度阈值为 4%，而女胎则需结合 X 染色体及常染色体指标进行分析。如果检测过早，胎儿 DNA 浓度可能不足，导致假阴性；若检测过晚，则会缩短临床干预的有效窗口。已有研究显示，男胎 Y 染色体浓度的增长趋势与孕周进展密切相关，并且受孕妇 BMI 的显著影响，这一关系直接决定了检测时点的合理性。与此同时，孕妇的个体差异对胎儿 DNA 浓度水平亦有重要作用。因此，针对上述难点与限制条件，本文希望构建合适的数学模型，综合考虑孕周、BMI 及其他个体特征，确定不同孕妇群体的最佳 NIPT 时点，并在此基础上优化判定胎儿异常的方法，为临床筛查策略的制定与孕期风险管理提供科学依据。

1.2 问题分析

附件提供了某地区以高 BMI 孕妇为主的 NIPT 检测数据。其中包括孕周、BMI、孕妇年龄、测序质量指标、胎儿染色体 Z 值、X/Y 染色体浓度及异常标记等相关数据。为优化 NIPT 的时点选择、寻找胎儿的异常判定方法，现结合已知条件与附件，建立数学模型，分析下述问题：

问题一：探讨男胎 Y 染色体浓度与孕周、BMI 等指标之间的关系，建立回归模型进行定量分析，并通过显著性检验评估其统计可靠性。

问题二：在男胎样本中，以 BMI 为主要分组依据，划定合理的区间范围，进而在各组内确定最优检测孕周，使 Y 染色体浓度尽早达到 4% 阈值，从而最大限度降低孕妇的潜在风险，并分析检测误差对结果的影响。

问题三：在 BMI 分组的基础上，进一步纳入孕妇身高、体重、年龄等变量，结合检测误差与 Y 染色体浓度达标比例，提出更为精细化的分组方案，确定各组的最佳检测时点，并对检测误差带来的影响进行系统评估。

问题四：针对女胎无法通过 Y 染色体进行判定的情况，以 13、18、21 号染色体的非整倍体结果作为参考，综合利用 X 染色体及相关染色体的 Z 值、GC 含量、测序读段及比例、BMI 等因素，构建判别模型，实现对女胎异常的有效识别。

为进一步直观展现整体思路，本文搭建以下框架：




图 1: 整体思路框架图

如图一，问题一采用 Beta-GAMM 模型，通过 REML 估计与显著性检验，揭示孕周与 BMI 对 Y 染色体浓度的作用。问题二利用 XGBoost 回归和阈值判定，结合覆盖率函数 $C(t)$ ，得到个体最早可靠孕周与分组推荐时点，并通过 ROC、AUC 等指标进行验证。问题三进一步引入 CV 与 σ ，在 BMI 分组的基础上构建风险最小化模型，以风险函数和覆盖率曲线联合求解最优检测时点，并评估稳健性。问题四针对女胎异常，采用 EasyEnsemble 分类器结合共形预测，设置双阈值机制，输出正常、异常与灰区三类判定。整体上，四个模块逐步递进，构成完整的检测时点优化与异常判定流程。

二、模型假设

1. 假设胎儿游离 Y 染色体浓度 Y 随孕周 G 单调增加, 同时受到母体 BMI 的负向影响。各孕妇样本相互独立, 检测结果之间不相关。

2. 假设检测误差主要来源于实验变异系数 (CV) 和模型残差标准差 σ , 其影响可通过灵敏度分析刻画。剔除极端异常值后, Y 的分布可近似服从 Beta 分布。

3. 当保守下界浓度 $L(G, BMI)$ 首次达到 4% 阈值时, 记为该孕妇的最早可靠检测时点 g^* ; 群体水平的推荐检测时点 t^* 定义为覆盖率函数 $C(t)$ 首次超过目标比例 p_0 的孕周。覆盖率函数假设随孕周单调不减且连续。

4. 将个体最早可靠孕周 g^* 定义为保守下界 $L(G, BMI) = \mu(G, BMI) - 1.645\sigma$ 首次达到 $0.04(1 + CV)$ 的孕周, 组内以覆盖率 $C(t)$ 近似真实比例, 推荐时点限定在 10-20 周且目标比例阈值取 $p_0 = 0.80$ 。

5. 时间权重 $w(t)$ 在 ≤ 12 周取 1、13-27 周取 3、 ≥ 28 周取 8, 失败代价为晚孕权重的两倍, 并在 10-20 周内最小化一次检 $R_1(t)$ 与两次检 $R_2(t_1, t_2)$ 得到 t^* 或 (t_1^*, t_2^*) 。该设定为简化性假设, 未考虑个体差异。

6. 仅保留总 GC 在 0.40-0.60 的样本, 残差标准差 σ 由交叉验证残差的稳健统计量估计并在 G 与 BMI 上近似常数, $\mu(G, BMI)$ 随 G 单调不降, BMI 以 g^* 为监督选切点分至不超过六组且每组样本量充足。本部分模型仅针对男胎检测时点问题, 女胎异常判定另行处理。

三、符号说明

表 1: 符号及其含义

符号	单位	含义
W	周	孕周中的“周”部分
D	天	孕周中的“天”部分 (0-6)
G	周	数值化孕周
G^*	周	校正孕周
T_{test}	日	检测日期
T_{LMP}	日	末次月经日期
ΔT	日	相邻两次检测间隔
A	0/1	非整倍体标签
H	0/1	胎儿健康状态标签
M	0/1/2	妊娠方式
t	周	候选检测孕周, 用于选择 t^*
t^*	周	各 BMI 组的最优检测时点
p_0	—	问题三中设定的达标比例阈值
y_{ij}	—	第 i 位孕妇第 j 次检测的 Y 浓度 (边界校正后 $y_{ij} \in (0, 1)$)
μ_{ij}	—	y_{ij} 的期望值
ϕ	—	精度参数, $\text{Var}(y_{ij}) = \mu_{ij}(1 - \mu_{ij})/(1 + \phi)$
g_{ij}	周	孕周
b_{ij}	kg/m ²	孕妇 BMI
a_{ij}	岁	母体年龄
c_{ij}	0/1	受孕方式指示: natural=0, ART=1
p_{ij}	次	产次
u_i	—	孕妇层随机截距, $u_i \sim \mathcal{N}(0, \sigma_u^2)$
σ_u^2	—	随机截距方差
η_{ij}	—	线性预测子, $\eta_{ij} = \log\{\mu_{ij}/(1 - \mu_{ij})\}$
$f_g(\cdot)$	—	孕周的一维平滑主效应
$f_b(\cdot)$	—	BMI 的一维平滑主效应
$f_{gb}(\cdot, \cdot)$	—	孕周×BMI 的张量积交互平滑
$B_k(\cdot), C_l(\cdot)$	—	样条基函数
θ, γ, δ	—	与基函数对应的系数向量/矩阵
$\lambda_g, \lambda_b, \lambda_{gb}$	—	平滑参数
S_g, S_b, S_{gb}	—	惩罚矩阵
$g(\cdot)$	—	链接函数
$\mathbf{1}(\cdot)$	—	指示函数
BMI	kg/m ²	孕妇体质指数
Y	—	胎儿游离 Y 染色体浓度
$L(G, BMI)$	—	保守下界浓度, $\mu(G, BMI) - 1.645\sigma$
g^*	周	个体的最早可靠检测孕周
$C(t)$	—	覆盖率函数, $C(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(g_i^* \leq t)$
p_0	—	达标比例阈值 (问题二取 0.6)
$\mu(G, BMI)$	—	非参数回归预测的 Y 浓度均值
σ	—	模型残差标准差
CV	—	实验测序变异系数
$\hat{Y}$	—	预测的 Y 浓度值
AUC	—	ROC 曲线下面积, 用于验证模型预测能力
REML	—	受限最大似然准则
EDF	—	有效自由度

表 2: 符号及其含义 (续)

符号	单位	含义
n	人	样本量
K	组	BMI 分组数 (不超过 6)
$\mathcal{B}$	—	BMI 组集合 $\{B_1, \dots, B_K\}$
$e_0, \dots, e_K$	kg/m ²	BMI 分组边界
$\mathcal{T}$	周	候选孕周集合 (10-20 周的七分制网格)
τ	—	有效阈值 $0.04(1 + CV)$
$C_k(t)$	—	第 k 个 BMI 组的覆盖率
$w(t)$	—	时间风险权重 (早 1, 中 3, 晚 8)
W_{fail}	—	未达标失败代价 (取晚孕权重的两倍)
$R_1(t)$	—	一次检测期望风险
$R_2(t_1, t_2)$	—	两次检测期望风险
(t_1^*, t_2^*)	周	两次检测的最优时点对
G_E, G_L	周	风险分段阈值 (12 与 28)
$z_{0.95}$	—	单侧 95% 分位常数 (1.645)
σ_{oof}	—	交叉验证残差的稳健标准差估计
GC	—	总 GC 含量 (仅保留 0.40–0.60)
U	无量纲	可判定性得分 (用于衡量样本被模型确定判别的置信度门限)
Z_{max}	无量纲	三条染色体Z值中的最大值, 用于构建组合特征
Z_{sum}	无量纲	三条染色体Z值之和, 用于构建组合特征
q_{pos}	概率	异常样本的平均置信度 (输出分数)
q_{neg}	概率	正常样本的平均置信度 (输出分数)
AP	概率	平均精度 (Average Precision) 评估指标
$Z_X \times \text{BMI}$	无量纲	X 染色体浓度与孕妇 BMI 的交互项
$Z_{\text{max}} \times QC$	无量纲	最大 Z 值与质控评分的交互项
$d21_{\text{gc}}$	比例差	21号染色体 GC 含量与整体样本 GC 含量之差

四、数据预处理

为保证后续问题求解过程中数据的一致性与可用性, 本文先对原始附件数据进行了清洗与预处理, 在缺失值处理过程中, 样本 B044 女胎的 BMI 数据缺失, 经数据核查与合理推断后, 手动补全为 36.19875, 此外具体步骤如下。

4.1 孕周格式标准化

首先, 借助 Excel 提取“周”和“天”两部分, 再利用 Python 正则表达式批量转换为数值型孕周:

$$G = W + \frac{D}{7} \quad (1)$$

其中 W 为整数周, D 为天数。该处理使孕周成为连续数值型变量, 可直接作为模型自变量。经过数值化的孕周既能为问题一中的回归分析提供可解释的自变量, 也便于问题二和问题三比较早、中、晚孕的检测时点, 同时还能作为问题四的时间分层参考, 保证各问题的分析都在统一的时间度量标准下进行。

4.2 孕周校正

在 Excel 中统一日期格式为 YYYY/MM/DD, 再利用以下公式计算末次月经与检测日期的差值, 以此修正部分受试中因记录错误或跳变导致的不合理孕周值。

$$G^* = \frac{T_{\text{test}} - T_{\text{LMP}}}{7} \quad (2)$$

校正孕周确保问题一的回归曲线更接近真实关系, 避免显著性检验受虚假拐点影响; 使问题二和问题三的最优时点准确度更高。同时, 剔除重复或顺序异常样本以确保问题四中的时间线一致。

4.3 异常值处理

通过 Excel 条件筛选与 Python 逻辑判断, 按以下规则处理: 仅保留同时满足 $10 \leq G^* \leq 40$ 、 $|G^* - G| \leq 2$ 且 $T_{\text{test}} \geq T_{\text{LMP}}$ 的记录; 否则 (任一条件不满足) 标记为异常并剔除。其余如日期前后颠倒或 $G^* > 48$ 的数据一并删除, 以减少极端值对问题一回归残差和显著性检验的干扰, 避免问题二和问题三风险函数与机会约束被异常样本扭曲, 同时在问题四的分类模型中降低噪声, 减少误报与漏报。处理前后的箱线图如下:




图 2: 异常值处理箱线图对比

其中，处理前孕周分布受极端值影响，上下须范围较大；处理后，异常记录被剔除，整体分布更加集中，中位数保持稳定，有效消除不合理数据的干扰。

为直观展示异常值处理对整体分布形态的影响，本节进一步绘制直方图：




图 3: 直方图对比

该图展现出，剔除前分布范围更宽，存在少量落在高孕周区间的极端样本；剔除后不合理点被清理，孕周数据主要集中在 10–25 周之间，分布更符合实际检测情况。

4.4 日期字段统一

在 Excel 中将不同格式的日期字段（YYYY-MM-DD 00:00:00）批量转换为：

$$\text{Date format} = \text{YYYY/MM/DD} \quad (3)$$

统一去除时分秒，并计算相邻检测的时间间隔 ΔT 。该处理使问题一的回归分析能够利用时间差解释梯度效应，同时为问题二和问题三提供孕周达标点及复检间隔的精确计算依据，并确保问题四中检测时点与结局标签对齐，避免错配。为了直观展示相邻检测间隔的分布特征，绘制下图：




图 4: 相邻检测间隔分布图

该图展示了相邻检测间隔的频数分布及其核密度估计。大多数间隔集中在 1–3 天，少数样本间隔较长，呈现长尾分布。

4.5 非整倍体结果数值化

首先利用 Excel 统一文本字段取值，再将其映射为二值变量：若检测结果包含任一非整倍体，则赋值为 1；若结果为空或为阴性，则赋值为 0。

$$A = \begin{cases} 1, & \text{检测到任一非整倍体} \\ 0, & \text{未检测到} \end{cases} \quad (4)$$

该变量便于在问题一至问题三中先行筛选出“健康胎儿样本”，避免非整倍体异常干扰模型关系。在问题四中，该变量被用作分类模型的基准标签，用于模型的训练与性能评估，从而保证异常判定结果的可靠性。

4.6 胎儿健康状态变量定义

基于非整倍体检测结果，本节对每个样本进行归类，若检测到 13、18 或 21 号染色体存在非整倍体，则定义为“胎儿不健康”；若未检测到上述异常，则定义为“胎儿健康”。在此基础上构建二元变量 H ：

$$H = \begin{cases} 1, & \text{胎儿不健康} \\ 0, & \text{胎儿健康} \end{cases} \quad (5)$$

该变量在问题一至问题三中用于分层比较健康与异常样本，以检验模型结果在不同群体中的一致性；在问题四中作为模型构建与评价的参照标准，确保异常判定结果的可信度。

4.7 妊娠方式数值化

在 Excel 中对妊娠方式的原始记录进行规范化，统一为“自然受孕”“试管婴儿”“人工授精”三类。随后将其映射为数值型变量，分别如下式将其数值化为 0, 1, 2。

$$M \in \{0, 1, 2\} = \{\text{自然受孕}, \text{IVF}, \text{IUI}\} \quad (6)$$

在问题一中该变量作为混杂控制进入回归分析，保证效应不因人群差异而偏移；提高问题二和问题三中最优检测时点估计在不同人群间的适用性；控制问题四不同妊娠方式的系统性偏差。

五、问题一的求解：Beta-GAMM 模型的建立

在解答问题一之前，我们进一步处理了附件数据。由于胎儿 Y 染色体浓度为比例型变量，理论取值范围为 $[0, 1]$ ，边界值可能导致 Beta 回归对数似然计算的干扰，因此将原始变量 y_{frac} 修正为 $y_{\text{frac_adj}} \in (0, 1)$ ，以确保因变量严格位于开区间。同时，对孕周与 BMI 中的极端异常值采用温莎化方法处理，以减弱异常值对平滑估计和随机效应建模的影响，从而保证分布假设成立。

此外，我们尝试进行主成分分析（PCA），以考察潜在的低维结构。然而结果显示，前两主成分的累计解释率较低，无法有效反映孕周的非线性效应及 BMI 的交互作用。基于此，PCA 未被纳入最终框架，而选择直接采用 Beta-GAMM 建模。

5.1 Beta 分布

为刻画胎儿 Y 染色体浓度与孕周、BMI 的关系，设第 i 位孕妇在第 j 次抽血（同一孕妇可多次抽血）测得的 Y 浓度（经边界校正）为 $y_{ij} \in (0, 1)$ ，则

$$y_{ij} | \mu_{ij}, \phi \sim \text{Beta}(\alpha_{ij}, \beta_{ij}), \quad \alpha_{ij} = \mu_{ij}\phi, \quad \beta_{ij} = (1 - \mu_{ij})\phi. \quad (7)$$

式中 $\mu_{ij} = \mathbb{E}(y_{ij}) \in (0, 1)$ 为该次检测的期望浓度， $\phi > 0$ 为精度（precision）参数以控制方差大小。由 Beta 分布性质，可得：

$$\mathbb{E}(y_{ij}) = \mu_{ij}, \quad \text{Var}(y_{ij}) = \frac{\mu_{ij}(1 - \mu_{ij})}{1 + \phi}. \quad (8)$$

其中， μ_{ij} 代表在特定孕周 g_{ij} 与 BMI b_{ij} 条件下的预期 Y 浓度均值； ϕ 越大，方差越小，意味着同一条件下不同检测的波动更小。Beta 分布保证因变量位于 $(0, 1)$ 区间，还量化了孕周与 BMI 对 Y 浓度的均值和方差特征，为后续关系模型的构建和显著性分析提供依据。

5.2 logit 链接函数

在确认观测 $y_{ij} \sim \text{Beta}(\mu_{ij}\phi, (1 - \mu_{ij})\phi)$ 后，我们继续将均值参数 $\mu_{ij} \in (0, 1)$ 与孕周与 BMI

构造成可加关系；为此把 μ_{ij} 映射到实数轴以便采用广义可加混合模型的线性预测子与惩罚平滑。由于其单调可逆且数值稳定，选用 *logit* 链接，设： $g(\cdot) = \log(\cdot / (1 - \cdot))$ ，则

$$\eta_{ij} = g(\mu_{ij}) = \log\left(\frac{\mu_{ij}}{1 - \mu_{ij}}\right), \quad \mu_{ij} = g^{-1}(\eta_{ij}) = \frac{1}{1 + e^{-\eta_{ij}}}. \quad (9)$$

μ_{ij} 表示在特定孕周 g_{ij} 与 BMI b_{ij} 条件下的预期 Y 浓度均值， η_{ij} 为线性预测子，后续将由孕周的非线性平滑函数、BMI 的平滑函数、二者的交互项以及孕妇个体随机效应共同构成。logit 链接将受限于 (0, 1) 的均值参数 μ_{ij} 映射到实数域，使其能够作为线性预测子的函数被孕周和 BMI 等变量建模，从而把二者对 Y 浓度的影响转化为可量化和可检验的关系。

5.3 结构方程

在给定 $y_{ij} \sim \text{Beta}(\mu_{ij}\phi, (1 - \mu_{ij})\phi)$ 之后， $\mu_{ij} \in (0, 1)$ 使其难以直接在实数线性空间中建模；据此引入 logit 链接将 μ_{ij} 映射到实数域，从而把孕周、BMI 及其交互项作为线性预测子 η_{ij} 的组成部分进行参数化，进而将二者对 Y 浓度的影响表述为可估计、可检验的函数关系。

$$\eta_{ij} = f_g(g_{ij}) + f_b(b_{ij}) + f_{gb}(g_{ij}, b_{ij}) + \beta_{aa}a_{ij} + \beta_c \mathbf{1}(c_{ij} = \text{ART}) + \beta_{pp}p_{ij} + u_i. \quad (10)$$

其中， g_{ij} 为第 i 位孕妇在第 j 次抽血时的孕周， b_{ij} 代表孕妇 BMI， a_{ij} 为母体年龄， c_{ij} 是受孕方式， p_{ij} 为产次； u_i 作为孕妇层随机截距， $\beta_{\cdot}$ 为线性系数。 f_g, f_b 为一维平滑主效应， f_{gb} 为张量积交互平滑。从而使孕周、BMI 及其交互作用与 Y 浓度的均值建立起明确的函数关系，把“Y 浓度与孕周、BMI 的相关特性”转化为可估计、可检验的数值模型。

1. 平滑函数

由于孕周和 BMI 对 Y 浓度的作用不是单纯的线性关系，而 BMI 也可能在不同区间呈现不同效应，应进一步寻找更为灵活的非线性模式。为此采用薄板回归样条来表示一维非线性主效应，在保证平滑性的同时，自动选择有效自由度避免过拟合。

$$f_g(g) = \sum_{k=1}^{K_g} \theta_k B_k(g), \quad f_b(b) = \sum_{l=1}^{K_b} \gamma_l C_l(b), \quad (11)$$

上式中 $B_k(g)$ 与 $C_l(b)$ 分别为孕周和平滑基函数， θ_k 与 γ_l 为相应系数。通过这一设定，孕周和 BMI 的非线性效应被形式化并数值化表达，使其对 Y 浓度的影响可以直接进入后续的关系模型和显著性检验。既能捕捉“早期平缓—中期陡升—后期趋缓”的孕周曲线，又避免过拟合

2. 张量积交互

前述一维平滑 $f_g(g)$ 与 $f_b(b)$ 已分别刻画了“孕周—浓度”和“BMI—浓度”的非线性关系；然

而，若 BMI 的改变会同步孕周曲线的形状，仅靠主效应相加不足以表达这种随 BMI 改变的孕周效应。为此，引入张量积样条构造联合非线性交互项 $f_{gb}(g, b)$ ：

$$f_{gb}(g, b) = \sum_{k=1}^{K_g} \sum_{l=1}^{K_b} \delta_{kl} B_k(g) C_l(b). \quad (12)$$

由上式可知， $B_k(g)$ 与 $C_l(b)$ 分别为孕周与 BMI 的一维样条基函数， δ_{kl} 为待估系数，系数按行列组成矩阵 $\Delta = (\delta_{kl})$ 。通过在孕周与 BMI 两个方向分别设置平滑度，实现对不同量纲与变化速率的合理拟合。

3. 随机截距

在同一孕妇身上往往存在多次检测记录，这些观测并非相互独立，而是共享一定的个体特征。为反映个体差异性，引入孕妇层随机截距：

$$u_i \sim \mathcal{N}(0, \sigma_u^2). \quad (13)$$

其中， u_i 表示第 i 位孕妇的随机效应，服从均值为 0、方差为 σ_u^2 的正态分布。这将未观测到的个体差异量化为方差，由此，模型既能揭示总体趋势，又能合理控制差异性，为相关特性的显著性检验提供保障。

4. 线性控制项

除孕周与 BMI 外，模型还加入母体年龄、受孕方式及产次等基本人口学因素作为线性控制项：

$$\beta_a a_{ij} + \beta_c \mathbf{1}(c_{ij} = \text{ART}) + \beta_p p_{ij}, \quad (14)$$

a_{ij} 表示母体年龄， c_{ij} 表示受孕方式（若为 ART 取 1，否则为 0）， p_{ij} 表示产次， β_a 、 β_c 与 β_p 为相应的线性系数。引入这些变量旨在控制可能影响 Y 浓度的差异，使主效应和交互效应的估计更加准确。然而在本节中，这些控制变量的解释增益有限，过多纳入可能引入噪声，对主要结论贡献不大，因此最终选择的主模型 m3 并未保留这些控制项。

5. 最终模型

综合式子 (10)–(14)，得到 Beta-GAMM 线性预测子：

$$\eta_{ij} = f_g(g_{ij}) + f_b(b_{ij}) + f_{gb}(g_{ij}, b_{ij}) + \beta_a a_{ij} + \beta_c \mathbf{1}(c_{ij} = \text{ART}) + \beta_p p_{ij} + u_i, \quad (15)$$

与式子 (7)–(9) 的 Beta-logit 框架结合，构造因变量的分布假设与均值结构。满足了 Y 浓度这一比例型变量的取值特性，同时也使孕周效应、BMI 效应及其交互作用能够在统一的统计框架下得到量化与检验。

5.4 极大似然与惩罚 REML 估计

在明确线性预测结构后，下一步需要估计模型参数，以便将非线性主效应、交互项以及随机效应变为可量化的数值结果。为此，将全部待估参数记为：

$$\Theta = (\beta, \theta, \gamma, \delta, \sigma_u^2, \phi), \quad (16)$$

β 表示线性控制项系数， θ 与 γ 分别为孕周与 BMI 主效应的平滑系数， δ 为交互项的系数矩阵展开形式， σ_u^2 为孕妇层随机截距的方差， ϕ 为 Beta 分布的精度参数。

基于 Beta 分布假设，可得对数似然函数：

$$\ell(\Theta) = \sum_{i,j} \left\{ \log \Gamma(\phi) - \log \Gamma(\mu_{ij}\phi) - \log \Gamma[(1-\mu_{ij})\phi] + (\mu_{ij}\phi - 1) \log y_{ij} + [(1-\mu_{ij})\phi - 1] \log(1-y_{ij}) \right\}. \quad (17)$$

该式表明，每一次观测 y_{ij} 都通过 μ_{ij} 和 ϕ 被纳入整体似然的计算， μ_{ij} 连接孕周、BMI 及其交互对均值的影响， ϕ 则刻画在同一条件下的波动程度。最大化该函数即可在数据驱动下同时估计均值与方差；结合惩罚项并采用 REML，则在拟合精度与模型复杂度之间实现平衡，为后续选定的优秀模型 m3 提供依据。

样条与随机效应通过二次型惩罚加入惩罚似然：

$$\ell_p = \ell - \frac{1}{2} \left(\lambda_g \theta^\top S_g \theta + \lambda_b \gamma^\top S_b \gamma + \lambda_{gb} \delta^\top S_{gb} \delta + \sigma_u^{-2} u^\top u \right), \quad (18)$$

REML 可同时估计平滑参数 λ 与方差分量 σ_u^2 ，在拟合精度与平滑程度之间自动取得平衡，从而有效避免过拟合。

5.5 孕周×BMI 对 Y 染色体浓度的相关特性

模型比较结果进一步验证了 5.3 节结构方程设定 的合理性：（i）孕周效应显著且呈非线性，是决定 Y 浓度的核心因素；（ii）BMI 的主效应有限，但其与孕周的交互至关重要，高 BMI 孕妇在相同孕周下的浓度曲线整体右移，即达到同一阈值需要更晚孕周；（iii）个体差异显著，需要通过随机截距加以控制。这一点在 m2 升级为 m3 时 REML 的明显下降中得到定量体现（见表 3）。

表 3: m1-m4 模型结构与拟合优度对比

模型	固定项（主效应/交互/控制）	随机效应	REML
m1	$f_g(g)$	u_i	-2269
m2	$f_g(g) + f_b(b)$	u_i	-2270
m3	$f_g(g) + f_b(b) + f_{gb}(g, b)$	u_i	-2284
m4	$f_g(g) + f_b(b) + f_{gb}(g, b) + \text{控制 } (a, c, p)$	u_i	-2279

由上表可知，相比 m_2 ，引入孕周 $\times$ BMI 张量交互后 (m_3) REML 从 -2270 明显下降至 -2284 ，交互能实质提升解释力。在 m_3 基础上再加入年龄、受孕方式、产次等线性控制 (m_4)，REML 回升至 -2279 ，证明这些控制项在本题中的边际贡献有限，可能带来噪声或自由度浪费。

在数值证据的基础上，本文进一步通过可视化直观地揭示孕周与 BMI 的交互模式。




图 5: 孕周的非线性主效应

图中表现出孕周对 Y 浓度的非线性主效应及其 95% 置信带。可以看到，曲线整体呈单调上升趋势，说明孕周越大，预测的 Y 浓度越高。在 12–16 周区间内效应接近于零，增长较为平缓；从 17 周开始效应显著增强，18–22 周是上升最为陡峭的阶段，之后至 25 周仍保持上升但斜率有所减缓。灰色置信带在全区间均未跨越零轴，进一步表明孕周效应在统计上显著，是决定 Y 浓度水平的主要因素。

在数值证据之外，进一步通过可视化可以更直观地揭示孕周与 BMI 的交互模式，如图所示，高 BMI 孕妇的浓度–孕周曲线整体右移，说明达到同一阈值所需孕周更晚。




图 6: 孕周与 BMI 对 Y 浓度的交互效应图

图6 展示了孕周与 BMI 对 Y 浓度的交互效应。横轴为孕周，纵轴为 BMI，颜色及等高线表示预测 Y 浓度水平。可以看到，随着孕周增加，预测值整体上升，表明孕周是决定浓度变化的核心因素。同时，高 BMI 区域的预测值整体偏低，等高线整体右移，说明 BMI 在调节 Y 浓度的增长速率方面具有显著作用，即高 BMI 孕妇需要更晚的孕周才能达到相同的浓度水平。

综上所述，第一问得到如下相关特征：

1. 孕周增加时预测值单调上升，在15-25周区间由约0.05升至0.11且 18-22 周增速最快。
2. 在同一孕周下，BMI 增加会使预测值降低，例如 20 周时由约 0.08 降至 0.06，降幅约 25%。
3. 等高线随 BMI 升高整体右移，表明高 BMI 孕妇达到同一浓度水平需延后约 1-2 周。
4. 预测值整体在 0.04-0.12 范围波动，孕周方向的变化幅度远大于 BMI 方向，说明孕周为主导因素，BMI 主要起调节作用。

5.6 显著性检验

在显著性检验方法的选择上，本文首先尝试使用经典的卡方拟合优度检验。但该方法主要面向离散型频数数据，而本题的因变量是连续比例型变量，同时模型中还包含非线性平滑和随机效应，因此卡方检验在适用条件上存在明显局限。鉴于此，本文改用更为适配的检验工具。具体而言，平滑项近似卡方检验能够判断非线性样条的有效自由度是否显著偏离零函数，嵌套离差检验可以用于评估交互项引入的必要性，而 REML 与 AIC 等拟合优度指标则可以在解释力与模型复杂度之间提供平衡。

表 3 给出了不同模型的 REML 对比结果。为了更直观地呈现拟合优度与模型复杂度之间的

权衡关系，下图绘制了 REML 与 EDF 的联合比较，展现m3的高适配性：




图 7: 最优模型选择：REML-EDF对比图

改图展示了各候选模型在复杂度（EDF）与拟合优度（REML）之间的权衡关系。m1 与 m2 自由度较低但 REML 较高，拟合不足，m4 虽然复杂度最高，但 REML 并未改善，提示可能过拟合，m3 位于效率前沿的最优点，REML 最低且复杂度适中，在拟合度与简洁性之间达到最佳平衡。

从定量分析来看，m2 升级为 m3 时 REML 值下降 14，而 m3 增加控制项得到 m4 时 REML 仅回退 5，这说明加入控制变量并未带来实质性的拟合改进。在 mgcv 框架下，平滑项的统计显著性通常以近似卡方检验和 p 值报告。结果显示孕周平滑项的自由度显著大于 1 且对应的 p 值小于 0.001，说明孕周效应明显且呈非线性。BMI 平滑项的自由度接近 1 且置信带跨越零，说明其单独作用不显著；孕周与 BMI 的张量交互项同样在统计上高度显著，并且在 REML 改善中得到定量体现，表现为 m2 到 m3 的 ΔREML 为 14。由于 REML 值越小拟合效果越好，m3 的 REML 为 2284，相比于 m2 的 2270 具有更优拟合性能（见表2）。

进一步观察效应模式可见，在较高 BMI 水平下，孕周-浓度曲线整体向右移动，即达到相同检测阈值所需孕周更晚。此外，为确保显著性结果建立在合理的模型假设之上，还需检验模型的拟合与残差表现。如以下两张图所示，




图 8: 残差与线性预测子

上图显示残差大多分布在零附近，点云对称且没有明显模式，红色平滑曲线贴近零轴，波动范围控制在 ± 0.2 以内，未出现 U 型或斜坡型趋势。换言之，残差没有系统性偏差，方差也基本稳定，仅在极端预测值处有少量离散点。这说明模型对均值结构的刻画是充分的，假设条件未被违背，因此前面得到的显著性检验和效应解释是可靠的。




图 9: 观测值与拟合值对比

图中展示大多数散点紧密分布在对角线附近，说明模型预测值与实际观测高度一致。红色平滑曲线几乎与 45° 虚线重合，仅在极端大于 0.18 的部分略有偏离，整体偏差幅度控制在 0.01 左右。点云分布覆盖范围 0.02–0.22，与拟合值区间基本一致，未出现系统性偏离或大规模异方差。结果表明 Beta-GAMM 模型能够准确刻画 Y 浓度随孕周与 BMI 的变化趋势，拟合精度较高，从而增强显著性检验与效应解释的可信度。

综上，显著性检验表明，孕周为主要决定因素，BMI 主要体现为调节作用，所建立的 Beta-GAMM 模型具备较高的拟合质量。

六、第二问的求解：孕周-BMI 检测节点模型与敏感性分析

在第一问中，本文已建立孕周与 BMI 对 Y 染色体浓度的非参数回归关系，并验证了 BMI 对检测可靠性的显著影响。然而，第一问尚不足为不同体型孕妇提供分层检测建议。本文在第一问的基础上引入分组设计和节点判定两个关键环节，将 BMI 作为分层变量，依据临床肥胖分界标准进行区间划分，从而量化不同 BMI 人群的差异。同时在每个分组内计算覆盖率随孕周的动态变化，确定目标节点 t^* 。此外，本问做了灵敏度分析与误差敏感性检验，以确保分组建议的高鲁棒性。

6.1 BMI 分组设计与样本特征

第一问的拟合结果显示，在相同孕周 G 下，母体 BMI 与 Y 浓度的回归均值 $\mu(G, \text{BMI})$ 呈负相关，高 BMI 会降低 Y 的可检测水平并推迟达到判定阈值（4%）的时点。这说明如果所有孕妇统一检测孕周，高 BMI 群体会更容易检测失败。因此，本问先按 BMI 分层，再在各组内计算个体的最早可靠孕周 g ，并计算每组的最优检测节点 t 。

1. 依据与方法

本文遵循“临床分界优先”的原则，以临床常用的 24、28 作为超重与肥胖的分界 [1]。将 $\text{BMI} \geq 24$ 视为需要重点管理的人群，同时又在肥胖区间内按等宽方式细分，每 2 个 BMI 单位为一档直至 36，极高 BMI (≥ 36) 单列成组。

$$[24, 28), [28, 30), [30, 32), [32, 34), [34, 36), [36, 46.9)$$

如上，设置最小样本量门槛以保证覆盖率估计与曲线平滑的稳定性，最终得到 6 个区间。

2. 分组结果

按照上述区间完成样本划分后，在每个 BMI 组内计算个体的最早可靠孕周 g^* ，并构造覆盖率函数：

$$\begin{cases} C(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(g_i^* \leq t), \\ t^* = \min \{ t : C(t) \geq p_0 \}. \end{cases} \quad (19)$$

式(23)中， $C(t)$ 表示在孕周 t 之前达到检测可靠性的样本比例， t 是该比例首次不低于目标阈值 p_0 的孕周，也就是组层面的推荐检测时点。整体上，各组样本量与 BMI 分布满足稳定估计

的要求，计算所得 t 随 BMI 提升而呈现系统性后移，这一结果与第一问中“BMI 升高推迟达到阈值”的结论保持一致。

接着本节对各 BMI 区间的样本量及中位数进行了统计。

表 4: BMI 分组样本特征表

BMI 组	样本量	BMI 中位数
24-28	45	25.8
28-30	38	29.1
30-32	32	31.1
32-34	28	33.0
34-36	26	35.1
≥ 36	21	37.8

可以看出，样本量随 BMI 升高逐渐减少，但仍满足基本的统计稳定性要求。同时，中位数随分组递增而上移。

6.2 检测节点的确定

为优化检测时机，本文先利用非参数回归估计在孕周 G 与 BMI b 条件下的 Y 浓度均值，然后以保守下界与固定阈值进行判定，得到每位受试者的最早可靠孕周 g^* 。再在分组层面利用覆盖率曲线 $C(t)$ 描述群体随孕周推进的阈值达到比例， $p_0 = 0.6$ 的孕周作为该组的最优检测时点 t^* ，从而避免高 BMI 人群的不利影响，并保证各分组在统一标准下比较。

1. 基于非参数回归的覆盖率判定模型

首先依托 Python 的 `xgboost` 与 `scikit-learn` 工具包，采用非参数回归方法对条件均值进行估计。我们选择 XGBoost 回归与随机森林回归刻画孕周 G 与 BMI b 的非线性作用及交互关系。在前期建模中，多元线性回归对高 BMI 人群存在低估，因此舍弃该方法，最终采用非参数模型作为主要工具。

$$\hat{\mu}(g, b) = \mathbb{E}(Y \mid G = g, B = b) \approx f(g, b). \quad (20)$$

式(20)总结了在孕周为 g 、BMI 为 b 时 Y 浓度的预测均值 $\hat{\mu}$ ，其中 $f(\cdot, \cdot)$ 表示通过非参数回归模型学习得到的孕周 G 与 BMI b 对 Y 浓度的条件均值函数，便于后续计算保守下界，从而判定个体在给定孕周是否已达到检测阈值。

其次，我们使用 $z_{0.95} = 1.645$ 的正态分位数与残差标准差估计 $\hat{\sigma}$ 构造保守下界：

$$L(g, b) = \hat{\mu}(g, b) - 1.645 \hat{\sigma}. \quad (21)$$

式(21)将“均值减去 1.645 个标准差”作为保守估计，避免因模型偏差导致过早给出检测时机，

此外 $\hat{\sigma}$ 为回归残差的标准差估计。在单体层面，以阈值 $\tau = 0.04(1 + CV)$ ，将浓度设为4% 浓度并考虑检测 CV 的放大在离散候选集合 $\mathcal{T}$ 上寻找最早孕周，公式如下：

$$g_i^* = \min \{ t \in \mathcal{T} : L(t, b_i) \geq \tau \}, \quad \mathcal{T} = \{10.0, 10.1, \dots, 26.0\}. \quad (22)$$

最后，在分组层面利用覆盖率曲线描述群体达到阈值的占比，并以此确定各组的最优检测时点。

$$\begin{cases} C(t) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(g_i^* \leq t) \\ t^* = \min \{ t : C(t) \geq p_0 \}, \quad p_0 = 0.6 \end{cases} \quad (23)$$

如上式所示， $C(t)$ 表示在孕周 t 之前已达到检测阈值的样本比例，而 t^* 定义为该比例首次不低于目标阈值 p_0 的孕周。由此， t^* 可作为该 BMI 分组的最早推荐检测时机。

2. 计算结果与分析

为直观展示不同 BMI 分组在孕周推进过程中的阈值达到情况，利用 Python 中的 matplotlib 工具绘制覆盖率曲线图，以孕周为横坐标、累计达到比例 $C(t)$ 为纵坐标，分别给出 6 个 BMI 分组的覆盖率变化趋势，以比较和展示各组达到设定阈值的差异。结果如下图所示：




图 10: 各组 BMI 覆盖率曲线图

由图 10 可见，BMI 24-28 组和 28-30 组的覆盖率在 15.5 周前后即可达到 60% 的阈值，而 BMI 32-34 组需至 15.2 周，34-36 组约为 15.5 周，BMI ≥ 36 组则需推迟到 24.8 周才能达到相同水平。整体上，低 BMI 人群能够在较早孕周实现稳定检测，而高 BMI 人群的检测时机显著延后，这表明 BMI 升高会延缓可靠检测窗口的出现。

为直观展现不同 BMI 分组在推荐孕周上的差异性，我们统计了各组在首次达到 60% 时的孕周 t^* 及对应覆盖率水平。并总结了各组的推荐孕周与对应覆盖率，用于支撑后续条形图的可视

化。

表 5: BMI 分组推荐孕周与覆盖率表

BMI组	BMI区间	样本量	中位BMI	推荐孕周(t^*)	覆盖率
28-30	28.0-30.0	206	29.18	14.6	72.8%
32-34	32.0-34.0	259	32.95	15.2	64.5%
30-32	30.0-32.0	332	30.84	15.5	97.0%
34-36	34.0-36.0	154	34.72	15.5	72.7%
24-28	24.0-28.0	15	27.88	24.8	100.0%
≥ 36	≥ 36.0	36	37.60	24.8	77.0%

表 5 显示了不同 BMI 分组的推荐孕周与覆盖率。BMI 28-30 组在 14.6 周覆盖率为 72.8%，30-32 组在 15.5 周达到 96.9%，32-34 组在 15.2 周仅有 63.6%，34-36 组在 15.5 周为 73.1%。相比之下，BMI 24-28 组和 ≥ 36 组均需推迟到 24.8 周才能分别实现 100.0% 和 77.0%。整体上，中低 BMI 人群可在 15 周左右达到阈值，而极低和极高 BMI 人群均表现出检测时机推迟的趋势。

依据上述结论，又利用 Python 的 `matplotlib` 库绘制条形图，以孕周为横坐标、各 BMI 组为纵坐标，将推荐孕周 t^* 及其覆盖率水平直观表现出来：




图 11: 各 BMI 组推荐孕周的条形摘要

由图 11 推断，不同 BMI 组的推荐孕周差异化明显。BMI 28-30、30-32、32-34 与 34-36 组的推荐孕周均集中在 14.6-15.5 周之间，覆盖率水平在 64%-97% 之间，表明中低 BMI 人群能够在孕中早期较快达到检测阈值。相比之下，BMI 24-28 组与 ≥ 36 组的推荐孕周显著推迟至 24.8 周，覆盖率分别为 100% 与 77%，因此在极低与极高 BMI 条件下，检测时机延后。

6.3 模型合理性与验证

确定以上最优时点后，本节将验证结论的可靠性，由于 XGBoost 相较于传统线性模型能更精

确地反映检测阈值随个体差异的变化，我们选取该模型做了下述分析。

1. 模型构建：XGBoost 非参数回归

为评估孕周 G 与 BMI b 对是否达到检测阈值的区分能力，本文使用 Python 实现非参数回归，采用 `xgboost` 与 `scikit-learn` 训练梯度提升树，并以随机森林回归作为对照模型。在本题中，首先利用回归模型得到条件均值函数：

$$\hat{\mu}_i = f(G_i, b_i), \quad (24)$$

其中 G_i 表示第 i 位孕妇的孕周， b_i 表示其 BMI， $f(\cdot, \cdot)$ 由 XGBoost 回归学习得到，用于表示孕周与 BMI 对 Y 染色体浓度的非线性影响， $\hat{\mu}_i$ 为在该条件下的期望浓度预测值。

在训练模型时隐含以下约束与优化目标，首先，预测值需满足

$$0 \leq \hat{\mu}_i \leq 1, \quad (25)$$

保证 Y 浓度比例在 0 到 1 的范围内。其次，模型参数 θ 依赖于最小化平方损失函数估计为：

$$\min_{\theta} \sum_{i=1}^n \left(y_i - f(G_i, b_i; \theta) \right)^2, \quad (26)$$

其中 y_i 为观测到的 Y 浓度， θ 为待估参数。式 (26) 反映了预测值与真实观测之间的偏差最小化原则，本模型中的核心优化目标。

再者，为将连续预测结果转化为“是否达标”，我们设定阈值 $\tau = 0.04$ ，并以训练残差的标准差 $\hat{\sigma}$ 表示为预测不确定性，进而定义标准化得分。

$$z_i = \frac{\hat{\mu}_i - \tau}{\hat{\sigma}}, \quad \hat{p}_i = \Phi(z_i), \quad (27)$$

在上述式子中， $\Phi(\cdot)$ 为标准正态分布函数， $\hat{p}_i$ 可解释为在 (G_i, b_i) 条件下达到阈值的概率估计。式 (27) 生成连续型评分，便于计算 ROC 曲线与 AUC 指标。

2. 验证指标与方法：ROC 曲线与 AUC

建立上述模型后，我们以真实标签 $y_i = \mathbf{1}(Y_i \geq \tau)$ 为阳性、以 $\hat{p}_i$ 为连续评分，沿阈值 $\kappa \in [0, 1]$ 扫描得到一族分类器 $\hat{y}_i(\kappa) = \mathbf{1}(\hat{p}_i \geq \kappa)$ ，据此计算：

$$\text{TPR}(\kappa) = \frac{\text{TP}(\kappa)}{\text{TP}(\kappa) + \text{FN}(\kappa)}, \quad \text{FPR}(\kappa) = \frac{\text{FP}(\kappa)}{\text{FP}(\kappa) + \text{TN}(\kappa)}. \quad (28)$$

式(28) 中 TPR 为真正率，反映模型对阳性的检出能力，FPR 为假正率，反映阴性被误判为

阳性的比例。改变阈值 κ 即得到 ROC 曲线 $(FPR(\kappa), TPR(\kappa))$ 。

随后，对 ROC 曲线的面积（AUC）作数值积分，衡量模型区分阳阴性的能力。

$$AUC = \int_0^1 TPR(FPR^{-1}(x)) dx. \quad (29)$$

AUC 的范围为 $[0, 1]$ ，数值越大就代表总体区分能力越强。数值结果 $AUC \approx 0.818$ ，表明“孕周+BMI 的非参数回归评分”对“是否达到 4% 阈值”判断准确。进一步用 Youden 指数：

$$J(\kappa) = TPR(\kappa) - FPR(\kappa) \quad (30)$$

选择最佳阈值 $\kappa^* = \arg \max_{\kappa} J(\kappa)$ ；在本数据上， $\kappa^* \approx 0.787$ ，对应的 $TPR \approx 0.872$ 、 $FPR \approx 0.351$ 。

平衡“检出率”与“误报率”，用于证明回归评分作为判别依据的可用性结合本数据，综上所述，由公式得出的 ROC 曲线如图所示，




图 12: ROC 曲线图

由图可见，ROC 曲线整体位于对角线之上，模型在不同阈值下均表现出良好的判别能力。其曲线下面积 AUC 为 0.818，说明孕周与 BMI 的非参数回归模型在是否达到 4% 的区分上具有较高准确性。Youden 指数在阈值约 0.787 处取最大值，此时灵敏度约为 0.872，特异度对应的 FPR 为 0.351，表明模型在保持较高检出率的同时，误判率处于可接受范围。整体而言，该模型能够较稳定地平衡对“达到 4% 阈值”孕妇的检出率与对“未达到阈值”孕妇的排除率，说明其在

检测节点判定中的判别能力较为稳定，从而验证了模型在问题二求解中的适用性。

3. 鲁棒性检验：检测误差敏感性分析

为检验结果在实验测序误差和模型残差波动下的可靠程度，构造检测变异系数CV与残差尺度因子 σ -scale的二维网格，并在每一格上重新计算组层面的推荐孕周 t^* 。记

$$LB(G, b; CV, s) = \hat{\mu}(G, b) - z_{0.95} \cdot s \hat{\sigma}, \quad \tau(CV) = 0.04(1 + CV), \quad (31)$$

式子中 $z_{0.95} = 1.645$ 为分位数， $s \in \{0.8, 1.0, 1.2\}$ 为残差放缩因子， $\tau(CV)$ 为随CV放大的保守阈值。对每位个体在离散孕周集合 $\mathcal{T} = \{10, 10.1, \dots, 26\}$ 上找寻最早满足 $LB(G, b; CV, s) \geq \tau(CV)$ 的周数，得到个体 $g_i^*(CV, s)$ ，再根据式(32)计算覆盖率曲线与推荐孕周 $t^*(CV, s)$ ：

$$\begin{cases} C(t; CV, s) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(g_i^*(CV, s) \leq t), \\ t^*(CV, s) = \min\{t : C(t; CV, s) \geq p_0\}, \quad p_0 = 0.6. \end{cases} \quad (32)$$

将上述过程在matplotlib库绘制，以不同色阶对应各BMI组在不同误差设定下的推荐孕周，最终以热力图的方式呈现：




图 13: CV 与 σ 倍数下的组推荐孕周灵敏度分析热力图

上图直观的展现出，在 $CV = 5\%, 10\%, 15\%$ 与 σ 取 0.8, 1.0, 1.2 的组合下，各 BMI 组的推荐孕周存在明显差异。对于 28-30、32-34 组，推荐孕周集中在 14.6-15.5 周之间，仅在高误差条件下 ($\sigma = 1.2$ 且 $CV = 15\%$) 推迟至 23.3 周。30-32 与 34-36 组表现相似，常规情况下的推荐孕周约 15.0-15.5 周，高误差情景下延后至 23.5-24.8 周。相比之下，BMI ≥ 36 组受误差影响最为显著，在低误差时节点约为 15.5 周，但当 $CV = 10\%$ 或 15% 且 $\sigma \geq 1.0$ 时，推荐孕周延后至 24.8-26.0 周。整体规律表明，检测误差对推荐孕周的影响随 BMI 升高而增强，高 BMI 人群的检测时机更易受到实验条件波动的推迟效应，而中低 BMI 人群则相对稳定。

七、第三问的求解：风险最小化的 NIPT 时点与分组策略

问题三使用的数据在第二问的基础上，用excel统一按总 GC 在 0.40 到 0.60 的条件进行筛选，同时将“孕周”规范为数值化的 G ，并保留 BMI、年龄、身高、体重与测序质量指标等变量。异常值与缺失值沿用第二问的规则处理。接着，本节在 Python 中以非参数回归估计 $\mu(G, \text{BMI})$ ，并用交叉验证残差估计 σ ，据此通过保守下界 $L(G, \text{BMI})$ 作为判定达标的变量，并在该基础上定义覆盖率与风险函数。

7.1 分组变量变化与动因

第三问在第二问基础上新增三类约束，其一，检测时点限定于可行窗口 $\mathcal{T} = \{t : 10 \leq t \leq 20\}$ 。其次，改变判别标准，在计入实验波动 (CV) 后，Y 浓度的保守估计不低于 0.04，同时在群体层面将 $p_0 = 0.80$ 作为新判定准线。最后，引入按孕期分段的时间风险权重 $w(t)$ 及失败代价 W_{fail} 以量化过早或过晚检测的成本。综上，我们用非参数回归估计 $\mu(G, \text{BMI})$ ，并在孕周维度施加单调不降约束。误差用交叉验证残差标准差 σ ，并将保守下界首次达到阈值时的孕周定义为个体最早可靠时点 g^* 。此外，我们只保留总 GC 落在 $[0.40, 0.60]$ 的样本。约束条件用公式表示如下：

$$\begin{cases} \mathcal{T} = \{t : 10 \leq t \leq 20\} \\ \tau = 0.04(1 + \text{CV}), \quad p_0 = 0.80 \\ g^* = \min\{t \in \mathcal{T} : \mu(G, \text{BMI}) - 1.645\sigma \geq \tau\} \end{cases} \quad (33)$$

据此，分组由第二问的按 BMI 分布的固定分位数改为以 g^* 为监督信号，确定 BMI 分段切点。具体来说，我们用 CART 回归树，将 BMI 做为自变量、 g 作为求解目标在 Python 中拟定边界，约束不超过 6 个叶结点并设置每叶样本量下限，从而得到有序的分段区间 $e_0 < e_1 < \dots < e_K$ 。其中，若数据量或稳定性不足则回退为不超过 6 组的 BMI 分位分段。最终的分组结果如下表所示：

表 6: 问题三 BMI 分组表

BMI 区间	样本量 n
26.6–29.1	61
29.1–30.1	86
30.1–31.6	152
31.6–32.9	104
32.9–34.2	93
34.2–46.9	135

对比问题二中的分组表，可以看出，问题三的 BMI 分组由问题二的等宽或固定分位区间调整为不等宽边界，此外中间段 29–34 被细化为四个更窄的小组，两端区间被合并，与现实实际情况更相符。

7.2 达标判定与覆盖率定义

达标判定旨在把连续的 Y 浓度转为二元事件，从而统一判断标准。覆盖率定义用于描述在孕周 t 之前已达标的人群比例，以量化各 BMI 组的可检测性，并作为后续风险计算与最优检测时点选择的直接依据。

1. 有效阈值与保守下界

为把“浓度达到 4%”这一临床阈值转化为可计算、可比较的判定标准，先将名义阈值按实验变异放大，得到有效阈值：

$$\tau = 0.04(1 + CV) \quad (34)$$

其中 0.04 表示 4% 的名义达标线， CV 为实验测序的变异系数， τ 为用于判定是否“可靠达标”的有效阈值，使偶然的波动不对最终的结果造成大的影响。

在给定孕周 G 与 BMI 的条件下，还需将预测的平均浓度依据残差懂得预留安全余量，得到更为稳妥的下界值，具体计算如下所示：

$$L(G, BMI) = \mu(G, BMI) - 1.645\sigma \quad (35)$$

式中 $\mu(G, BMI)$ 为非参数回归得到的 Y 浓度均值预测， σ 为基于交叉验证残差的标准差估计，常数 1.645 为单侧 95% 分位数； $L(G, BMI)$ 给出在统计意义上更保守的浓度下界，用于与式 (34) 的阈值比较，进而确定该孕周是否“已可靠达标”。

2. 个体可检孕周的界定方法

为把个体层的达标时间落实到可操作的检测周上，定义最早可靠孕周如下，将周数范围划定

在10-20确保统一标准:

$$g_i^* = \min \{ t \in \mathcal{T} : L_i(t) \geq \tau \} \quad (36)$$

其中 $\mathcal{T}$ 为可行窗口的七分制周网格, $L_i(t)$ 为第 i 位孕妇在孕周 t 的保守下界, 由均值预测减去单侧百分之九十五标准差倍数组成, τ 为按实验变异系数放大的有效阈值。该定义使 $L_i(t)$ 首次不低于 τ 的最早 t , 据此保证个体判定具备安全边际。

在给出基于覆盖率与风险的最优时点之前, 我们先绘制并分析模型在测试集上的 ROC 曲线与 PR 曲线, 来验证算得的4% 能否作为有效辨别是否达标的标准:




图 14: 达标概率判别效果图

从图可见, ROC 的曲线下面积 (AUC) 为 0.869, 表明模型对是否达标的判别能力较强, PR 曲线的面积 (PR-AUC) 为 0.678, 在正类比例约 10% 的不平衡条件下属于中等水平。进一步看, 当召回率约为 0.8 时, 精确率约为 0.3, 也就是说, 尽可能捕获“真正达标”个体会引入一定数量的误判, 需配合后续复核。综上, 该模型适合用于风险排序与达标概率输入, 能够支撑覆盖率估计与最优时点选择, 但其精度有限, 不宜作为个体层面的确诊直接使用。

3. 组覆盖率与目标比例

在组层面, 我们将个体的最早可靠孕周 g_i^* 汇总为随孕周 t 单调非降的覆盖率曲线。它度量截至孕周 t 已达到可靠检测的样本占比, 记为第 k 个 BMI 组的覆盖率 $C_k(t)$ 。

$$C_k(t) = \frac{1}{n_k} \sum_{i \in B_k} \mathbf{1}(g_i^* \leq t) \quad (37)$$

式中 n_k 表示组 k 的样本量, B_k 为该组的个体集合, $\mathbf{1}(\cdot)$ 为指示函数, 当事件成立时取 1 否则取 0。因此 $C_k(t)$ 等于“在孕周 t 前已达标的人数”除以“该组总人数”。换句话说, $C_k(16) = 0.80$ 就表示该组有八成孕妇在 16 周前已经满足可靠检测条件。

为了把曲线落到可执行的单一时点上，还需要给出达到既定覆盖比例的最早孕周，作为组内的推荐检测时点。

$$t_{k,p_0} = \min\{t \in \mathcal{T} : C_k(t) \geq p_0\} \quad (38)$$

其中 p_0 为目标覆盖比例，本问取 0.80， $\mathcal{T}$ 为 10 到 20 周的可行孕周网格。于是 t_{k,p_0} 就是组 k 在该可行窗口内首次达到目标覆盖率的周数，也就是该组“一次检测”的推荐时点。

为呈现模型在实际判定时的检出与误报情况，下面按照F2指标自动选出在 $t = 0.081$ 时给出测试集的混淆矩阵，展示真正例、假正例、真负例与假负例的数量分布。




图 15: 判定混淆矩阵图

图中表现了四类计数：真负 $TN = 116$ 、假正 $FP = 25$ 、假负 $FN = 3$ 、真正 $TP = 14$ 。由此得到正类召回率 $\text{Recall} = \frac{TP}{TP+FN} = \frac{14}{14+3} \approx 0.82$ ，精确率 $\text{Precision} = \frac{TP}{TP+FP} = \frac{14}{14+25} \approx 0.36$ ，总体准确率 $\text{Acc} = \frac{TN+TP}{158} \approx 0.82$ ，因此我们得到结论：在“召回优先”的阈值设置下，模型几乎不漏检正类（仅 $FN = 3$ ），但付出一定误报代价（ $FP = 25$ ）；因此可用于风险筛查与后续覆盖率计算的打分器，不宜直接作为确诊依据。

4. 可行时窗与单调性

$$\mathcal{T} = \{10, 10 + \frac{1}{7}, \dots, 20\} \quad (39)$$

候选孕周集合 $\mathcal{T}$ 仅在 10 到 20 周的七分制网格内搜索，保证时点可操作且与临床流程一致。

$$\mu(G, \text{BMI}) \text{ 对 } G \text{ 单调不降} \quad (40)$$

对同一 BMI 的浓度均值随孕周单调不降，实际实现时用“沿孕周方向的累计最大值”保证单调性。这样可避免非参数回归在边缘处振荡引入的反常下降。

7.3 风险函数与最优时点求解

为满足第三问“同时考虑母体特征、检测误差与达标比例”的建模要求，首先明确核心变量及其取值范围，以保证后续判定与优化在受控域内进行。相应的变量集合定义为：

$$\text{CV} \in \{0.05, 0.10, 0.15\}, \quad \sigma = \hat{\sigma}_{\text{oof}}, \quad G \in [10, 20], \quad \text{BMI} > 0. \quad (41)$$

式(41)中，CV 表示实验变异系数并取三档代表水平， σ 为基于交叉验证残差得到的稳健标准差估计， G 在 10 到 20 周的离散网格内取值以贴合临床排期，BMI 为正实数。随后给出数据质量与分组稳定性的硬性约束，使不同组别的覆盖率与风险可直接比较。约束写作：

$$\text{GC} \in [0.40, 0.60], \quad |\mathcal{B}| \leq 6, \quad n_k \geq n_{\min}. \quad (42)$$

式(42)要求仅使用总 GC 处于区间 $[0.40, 0.60]$ 的样本以统一测序口径，BMI 分组数不超过六组以避免过细划分，每个组的样本量不少于 $n_{\min}$ 以保证统计稳定。

最后为量化“过早或过晚检测”的代价，定义时间风险权重与未达标失败代价，使最优时点的选择有明确的损失函数依据：

$$w(t) = \begin{cases} 1, & t \leq 12, \\ 3, & 13 \leq t \leq 27, \\ 8, & t \geq 28, \end{cases} \quad W_{\text{fail}} = 2 \times 8. \quad (43)$$

其中， $w(t)$ 分别赋予早孕、中孕、晚孕递增的时间权重，未达标的失败代价 W_{fail} 设为晚孕权重的两倍用于体现结果不确定带来的额外损失。

1. 可行时窗与单调性约束条件

为保证检测时点可实施且与临床流程一致，第三问仅在固定的孕周网格内搜索最优时点，网格步长取一天。该可行集合定义为

$$\mathcal{T} = \left\{ 10, 10 + \frac{1}{7}, 10 + \frac{2}{7}, \dots, 20 \right\}. \quad (44)$$

该式中 $\mathcal{T}$ 表示可供枚举的孕周集合，范围从 10 周到 20 周，间隔为 $1/7$ 周即一天。另一方面，模型应当尊重“孕周越大，平均浓度不应变低”的生理规律，因此对浓度均值施加单调性约束：

$$\mu(G, \text{BMI}) \text{ 对 } G \text{ 单调不降.} \quad (45)$$

这里 $\mu(G, \text{BMI})$ 为在孕周 G 和 BMI 取值下的 Y 浓度均值。实现时在每个 BMI 上对沿 G 轴的预测值取累计最大，以消除非参数回归在边缘带来的小幅回落。孕周往后推，模型给出的平均浓度不会比早期更低。

为评估分组后的风险结构并为后续的时间权重设置提供依据，下面将低风险为 0，中风险为 1，高风险为 2，并给出各 BMI 组的风险分布堆叠柱图。




图 16: “不同 BMI 分组的风险分”堆叠柱图

从数量上看，中风险在所有分组中占据主导地位，整体约为七成到九成；低风险随 BMI 上升呈下降趋势，低 BMI 组大约三成，而在最高 BMI 组已降至不足一成；高风险极少见，仅在 30.1-31.6 组出现少量，比例低于百分之五。换句话说，大多数孕妇处于需要谨慎安排检测时点的中间区域，极端早达标或极端晚达标都不常见。

从含义上看，这种分布说明不同 BMI 组的“按时达标难度”并不相同，BMI 越高越需要在可行窗口内更靠后的时点来保证稳定达标，因此在后续的最优时点计算中晚孕权重的影响更突出；同时高风险占比极低，提示通过合理的时点选择即可在不增加检测次数的前提下规避大部分延迟风险。

2. 一次检测的目标函数

在给定第 k 个 BMI 组与候选孕周 t 的条件下，需要把越早完成检测的时间代价与尚未达标的失败代价放到同一标尺上统一衡量。为此定义一次检测在孕周 t 的期望风险如下。

$$R_{1,k}(t) = C_k(t)w(t) + (1 - C_k(t))W_{\text{fail}} \quad (46)$$

式中 $C_k(t)$ 表示该组在孕周 t 前已达标的人群比例，用作达标概率的经验估计。 $w(t)$ 为时间风险权重，早孕取 1，中孕取 3，晚孕取 8。 W_{fail} 为未达标的失败代价，按晚孕权重的两倍设置。含义是达标越多就按时间权重计入成本，而尚未达标的部分按失败代价计入成本。通俗地说，这个式子把提前做检查的时间成本和没有达标的风险成本加在一起，得到一个可比较的总风险值。

在可行时窗内以最小化式 (46) 为准则确定该组的一次检测最佳时点。优化问题写作

$$t_k^* = \arg \min_{t \in \mathcal{T}} R_{1,k}(t) \quad (47)$$

其中 $\mathcal{T}$ 是 10 到 20 周的七分制离散网格。做法是对网格中的每个候选周数计算总风险并取最小者。简单来说，就是在 10 到 20 周之间挑出风险最低的那个周数，作为该 BMI 组的一次检测建议时点。




图 17: “各 BMI 组一次检最优周”柱状图

3. 两次检测的目标函数

$$R_{2,k}(t_1, t_2) = C_k(t_1) w(t_1) + (1 - C_k(t_1)) [C_k(t_2) w(t_2) + (1 - C_k(t_2)) W_{\text{fail}}] \quad (48)$$

两次检测的期望风险 $R_{2,k}$ 先考虑在第一次时点达标的情形，再考虑第一次未达标而在第二次时点达标或仍未达标的情形。

$$(t_{1,k}^*, t_{2,k}^*) = \arg \min_{t_1 < t_2, t_1, t_2 \in \mathcal{T}} R_{2,k}(t_1, t_2) \quad (49)$$

两次检测的最优时点对在同一网格内穷举 $t_1 < t_2$ 后选取风险最小的组合。

综上所述，可以得到按 BMI 分组后每组最佳 NIPT 时点应该如下表所示：

表 7: 问题三各 BMI 组最优 NIPT 时点

BMI 组	覆盖率 $\geq 80\%$ 最早时点	一次检最优周	两次检最优周 t_1	两次检最优周 t_2
26.6–29.1	20	10	10	$10 + \frac{1}{7}$
29.1–30.1	20	$14 + \frac{4}{7}$	10	$14 + \frac{4}{7}$
30.1–31.6	20	$16 + \frac{3}{7}$	$16 + \frac{3}{7}$	$16 + \frac{4}{7}$
31.6–32.9	20	$16 + \frac{5}{7}$	$16 + \frac{5}{7}$	$16 + \frac{6}{7}$
32.9–34.2	20	$16 + \frac{3}{7}$	$16 + \frac{3}{7}$	$16 + \frac{4}{7}$
34.2–46.9	20	$16 + \frac{3}{7}$	$16 + \frac{3}{7}$	$16 + \frac{4}{7}$

在 $[10, 20]$ 周的范围內，若将达标标准设为 80%，并按 $0.04(1 + CV)$ 放大閾值，则所有 BMI 组要达到 80% 人群达标的最早时间均为 20 周。

若按期望风险最小化，一检最优时点随 BMI 升高而后移：低 BMI 组约在 10 周，中等 BMI 约在 14 周左右， $BMI \geq 30$ 的各组集中在 $16 \sim 17$ 周附近。两检策略进一步降风险，对于 $BMI < 30$ 的人群，首次检测约在孕 10 周，复检安排在孕中期；对于 $BMI \geq 30$ 的人群，两次检测均集中在孕 16–17 周，检测间隔尽量缩短，以提高判定的可靠性。

7.4 检测误差敏感性分析

1. 误差模型设定

为了在统一框架下描述实验误差与模型不确定性，先给出两类误差源的取值范围与缩放方式。前者以实验变异系数表征，同一条件下多次测量的相对离散程度由此量化；后者以残差标准差的放缩系数表征，用以刻画模型在外部样本上的波动规模。

$$CV \in \{0.05, 0.10, 0.15\}, \quad \sigma_\alpha = \alpha \hat{\sigma}_{\text{oof}}, \quad \alpha \in \{0.8, 1.0, 1.2\} \quad (50)$$

我们尝试不同的波动容忍程度（CV）和波动幅度调整系数（ α ），来测试模型在不同“检测稳定性”要求下的表现。其中，CV 为实验变异系数，即同一样本反复测量的相对离散程度； $\hat{\sigma}_{\text{oof}}$ 为交叉验证外残差的标准差，反映模型在未见样本上的误差规模； α 为缩放因子，用于放大或缩小模型残差水平。

2. 错误扰动下的计算流程

在确定误差坐标后，需规定由误差到最优检测时点的计算链路。其传导流程如下：

$$\langle CV, \alpha \rangle \Rightarrow \tau_{\text{eff}} \Rightarrow g^* \Rightarrow C_k(t) \Rightarrow t_k^*, t_{1,k}^*, t_{2,k}^* \quad (51)$$

从设置误差出发，最终推导出包含一次检测和两次检测的每组最优时点。 τ_{eff} 为误差修正后的有效閾值， g^* 表示个体最早可检测周数， $C_k(t)$ 表示第 k 个 BMI 组在孕周 t 之前的达标覆盖率， t_k^* 为一次检测的最优周， $t_{1,k}^*$ 与 $t_{2,k}^*$ 为两次检测的最优周数。

3. 灵敏度报告与关键指标输出

为度量误差扰动对最优时点的影响，引入基于偏移量的灵敏度指标：

$$\Delta t_k^* = t_k^*(CV, \alpha) - t_{k, \text{base}}^*, \quad t_{k, \text{base}}^* \equiv t_k^* \text{在 } CV = 0.10, \alpha = 1.0 \text{ 时的基线值} \quad (52)$$

它代表了当前设置下的最优检测时间和基准设置下的最优检测时间之间的差值。其中， Δt_k^* 表示第 k 组在当前误差情景下的最优时点相对基线的偏移，正值为推迟，负值为提前。

4. 误差机制对结论的影响路径解析

误差的传导首先体现在阈值调整上。实验误差的存在意味着不能使用固定名义阈值，而需进行保守修正：

$$\tau_{\text{eff}} = \tau_0 \cdot [1 + 0.04 \cdot (1 + CV)] \quad (53)$$

式中， τ_0 为名义阈值，0.04 表示 4% 目标线强度，CV 为实验变异系数。

其次，模型误差影响保守下界的估计：

$$L_k(t) = \hat{m}_k(t) - z_q \cdot \alpha \cdot \hat{\sigma}_{\text{oof}} \quad (54)$$

其中， $L_k(t)$ 为第 k 组在孕周 t 的保守下界， $\hat{m}_k(t)$ 为预测均值， z_q 为分位数控制置信程度。

该两步机制最终传导至覆盖率曲线 $C_k(t)$ 的右移或缓升，从而推迟最早达标时点 g^* 和最优检测时点 t_k^* ，实现从误差到决策指标的连续传导。

为直观呈现“测序误差 CV 与模型不确定性（残差放大系数 α ）”对首次达到 80% 覆盖率孕周 t_{k, p_0} 的影响，图给出了各 BMI 组在 (CV, α) 网格上的灵敏度热力图。




图 18: 优化后检测误差敏感性热力图

图中各面板呈现清晰的单调后移,当 CV 或 α 增大时, $t_{k,p0}$ 只增不减,表明误差上升会推迟首次达标的最早孕周。定量表现如下:

- **28-30 组:** 低误差时 $t_{k,p0} \approx 11.3 \sim 13.7$ 周; 当 α 提至 1.2 后升至 ≈ 15.4 周, 推迟约 2 ~ 4 周。
- **30-32 与 32-34 组:** 由 14.4 ~ 15.4 周随误差增大逐步上移, 并在较高误差下触顶为 20 周, 推迟幅度约 4 ~ 6 周。
- **24-28 与 ≥ 36 组:** 几乎在各误差水平下均为 20 周, 体现窗口上限效应: 在 10-20 周内本就难以更早达到 80%, 误差上升不会使时点早于 20 周, 只会降低到线把握。

总体上, CV 与 α 的上升均会导致 $t_{k,p0}$ 向后移动, 且高 BMI 组更敏感: 中等幅度的误差即可将最早时点从 15 ~ 16 周推迟至 20 周。

问题四: 基于 EasyEnsemble 与共形预测的女胎异常判别模型

8.1 异常判定的依据与特征变量构建

为与临床筛查口径保持一致, 本文参照一项多中心大样本的 NIPT-plus 回顾性研究 (2021-2023 年, 样本量 16,798) 对对象与方法的界定, 并以三体判定遵循 Z-score 阈值作为基础规则,

以保证标签与临床“金标准”核实流程的一致性 [2]。

本题要求在已知样本为女胎的前提下，判断是否存在 13、18 或 21 号染色体的任意非整倍体异常。根据 AB 列标签，定义如下聚合学习目标：

$$y_{ANY} = \mathbb{I}\{T13 = 1 \vee T18 = 1 \vee T21 = 1\} \quad (55)$$

其中， $\mathbb{I}\{\cdot\}$ 表示指示函数，输出为 1 则说明存在任一染色体异常，输出为 0 表示无异常。然后引入综合质控得分 QC 以量化数据稳定性与偏倚程度，具体计算如下：

$$QC = z(\log(1 + \text{Reads})) + z(\text{Map}) - z(\text{Dup}) - z(\text{Filt}) - z(|GC - 0.5|) \quad (56)$$

此处 $z(\cdot)$ 表示标准化操作，Reads 为原始测序读段数，Map、Dup、Filt 分别为比对比例、重复比例与过滤比例，GC 表示总体 GC 含量。高质量样本应具备更高的 QC 值。我们设定 QC 分数下十分位数为筛选阈值，且 GC 必须在 [40%, 60%] 范围内，若不满足则判为灰区样本。

构建输入特征时，不仅包含基本变量，还添加交互项与偏倚相关指标，形成如下特征集合：

$$\begin{aligned} \mathbf{x} = [Z_{13}, Z_{18}, Z_{21}, Z_X, \text{BMI}, GC, \text{Reads}, \text{Map}, \text{Dup}, \text{Filt}, \\ |GC_{13} - GC|, |GC_{18} - GC|, |GC_{21} - GC|, Z_{13}^2, Z_{18}^2, Z_{21}^2, \\ Z_{\max}, Z_{\text{sum}}, Z_X \cdot \text{BMI}, Z_{\max} \cdot QC] \end{aligned} \quad (57)$$

其中 Z_{13}, Z_{18}, Z_{21} 为目标染色体 Z 值， Z_X 表示 X 染色体 Z 值以捕捉体系偏倚；BMI 代表孕妇体质指数； $|GC_c - GC|$ 表征染色体特异 GC 偏离； $Z_{\max}$ 和 Z_{sum} 分别为最大值和和， Z^2 项和交叉项用于捕捉非线性结构。综上，我们完成了包含基础特征、非线性项和交互项的特征向量 $\mathbf{x}$ 的输入模型。

为进一步明确三类染色体异常的具体分布情况以及目标变量 ANY 的类别不平衡特征，本文对阳性样本构成与总体类别比例进行了可视化分析：




图 19: 三染色体异常样本计数 (左) 与 ANY 类别分布 (右)

从左图可见，T18 染色体出现的最为频繁，是最主要的异常类别 ($n = 46$)，T13 和 T21 次

之，分别为 $n = 23$ 和 $n = 13$ 。右图展示了 ANY 类别的整体不平衡特征，其中阴性样本（ANY=0）占比高达 88.9%（ $n = 537$ ），而阳性样本仅占 11.1%（ $n = 67$ ）。另外，只要 T13、T18、T21 中任一条染色体异常，即为阳性，也就是 $ANY = 1$ 。

8.2 模型建立

1. ANY 风险分数模型

为估计样本为异常的概率，引入 EasyEnsemble 分类器，并采用 isotonic 单调回归对其概率输出进行校准，得到如下表达：

$$s = \Pr(y_{ANY} = 1 | \mathbf{x}) \quad (58)$$

此式子表示，如果要预测一个样本出现染色体异常的概率，需要通过它的输入特征 $\mathbf{x}$ 来估计。其中 s 是异常风险分数，范围为 $[0, 1]$ 。EasyEnsemble 通过欠采样加集成学习结构，提升了模型识别异常样本的能力，同时引入校准机制以优化模型输出概率的稳定性与可解释性。

在构建 ANY 风险预测模型之前，有必要对 Z 值在阳性与阴性样本间的分布差异进行探索性分析，以评估其判别能力。下图展示了 Z13、Z18 与 Z21 三个染色体的 Z 值在两类样本中的分布对比。




图 20: 三类染色体 Z 值在阳性与阴性样本中的分布

如图所示，三类染色体的 Z 值在阳性样本中均明显高于阴性样本，呈现出明显的右偏分布趋势。其中 Z13 在阳性组中的中位数约为 2.3，而阴性组接近 0，Z18 与 Z21 亦表现出类似的趋势。总之，无论是哪种染色体异常，异常组（阳性）的 Z 值都显著高于正常组，说明 Z 值在检测异常方面具有强的区分能力。

2. 不平衡性问题与建模选择

考虑数据中阳性样本占比较低，使用线性分类器易导致召回不足。EasyEnsemble 可在多个欠

采样子集中训练弱分类器并集成结果。

因此本文采用EasyEnsemble，从大多数的“正常样本”中反复抽取部分出来，再加上全部的异常样本，训练多个分类器，最后把这些分类器的结果合在一起,从而提高识别能力。

3. 共形预测下的误差控制机制

为了对模型输出的风险分数建立决策依据，引入 Mondrian 共形预测方法，定义一致性函数如下：

$$\alpha^{(+)} = 1 - s, \quad \alpha^{(-)} = s \quad (59)$$

通俗来讲，式子表明异常样本的一致性得分是 $1 - s$ ，正常样本的一致性得分是 s ；得分越小说明模型越有信心。

根据非一致性度量，在独立校准集上估计两个误报上界的分位点阈值：

$$q_+ = Q_{1-\varepsilon_+}(\alpha^{(+)}), \quad q_- = Q_{1-\varepsilon_-}(\alpha^{(-)}) \quad (60)$$

给出三分类输出规则如下：

$$\Gamma(\mathbf{x}) = \{1 : 1 - s \leq q_+\} \cup \{0 : s \leq q_-\} \quad (61)$$

其中 $\Gamma(\mathbf{x})$ 表示支持集合。若为 $\{1\}$ 则输出异常， $\{0\}$ 输出正常，否则为灰区。具体解释，就是如果模型对一个样本的异常打分够高或够低，就能给出异常或正常的判断；否则就归为不确定的灰区。

于是我们进一步设定阈值优化问题如下：

$$\min_{\varepsilon_-} U_{\text{rate}} \quad \text{s.t.} \quad \Pr(\text{异常判正常}) \leq \varepsilon_+, \quad \Pr(\text{正常判异常}) \leq \varepsilon_- \quad (62)$$

在满足上界约束的前提下最小化灰区占比 U_{rate} ，本研究最终选取 $\varepsilon_+ = 0.05$ 且 $\varepsilon_- = 0.30$ 。总体来说该式表示在确保把异常错判为正常的概率不超过 ε_+ ，把正常错判为异常的概率不超过 ε_- 的前提下，尽可能缩小不确定灰区的占比。

4. 最终判别策略

为清晰展示判断女胎是否异常的整个过程，我们整理了图 21 从收到检测样本开始，到最终判断结果的完整过程：




图 21: 女胎异常判别流程图

由流程图可知，在实际诊断流程中，首先对收到的 NIPT 女胎样本进行质控检查，若测序质量指标未达标则建议复抽或提高测序深度，否则进入下一步分析。随后构建包括 Z13、Z18、Z21、ZX、BMI、GC 含量及测序相关参数在内的多维特征，并以此训练 EasyEnsemble 分类模型，结合后续的概率校准输出样本属于异常类别的预测得分。在此基础上，引入共形预测方法设定双重阈值机制，分别对应对漏诊率和误报率的预设控制水平。最终通过分数与阈值的比较进行三类判定：若得分不高于正常类阈值则判为正常，若其一减得分不高于异常类阈值则判为异常，否则归类为灰区并建议复检。至此，完整的判别流程形成闭环，每一类样本均有明确的处置方案。

8.3 模型验证与评估

1. 评估指标与定义

在验证阶段，构建独立校准集与测试集。基于可判定子集，计算以下常用评估指标：

$$\begin{cases} \text{Recall} = \frac{TP}{TP+FN} \\ \text{Specificity} = \frac{TN}{TN+FP} \\ \text{Precision} = \frac{TP}{TP+FP} \\ F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \end{cases} \quad (63)$$

从上到下依次求解出在异常和正常样本中，真正正常并识别成功的模型率、异常样本中真正异常的的概率，以及精确率和召回率的加权平均值。

同时评估覆盖误差如下：

$$\text{cal_err_neg} = \Pr(\text{异常判正常}), \quad \text{cal_err_pos} = \Pr(\text{正常判异常}) \quad (64)$$

通过式 (64)，我们同时考虑正负两类误判率，从而综合评估模型的判别能力与实际可行性。

此外，为应对正负样本比例不平衡，采用精确率-召回曲线下的面积（AP）作为主性能指标。

验证共形预测方法在实际判别中的可行性与有效性，图 22 展示了校准集样本在 ANY 风险概率下的分布情况，以及相应的双重阈值区间构建结果。




图 22: ANY 风险概率分布与共形预测双重阈值划分（校准集）

如图所示，蓝色与橙色柱分别表示正常类与异常类在校准集中的预测概率分布，其在 $[0, 1]$ 区间的差异性明显。通过引入 $\epsilon_{\text{pos}} = 0.05$ 与 $\epsilon_{\text{neg}} = 0.3$ ，共形方法分别计算得到负类阈值 $q_{\text{neg}} = 0.124$ （虚线）与正类阈值 $1 - q_{\text{pos}} = 0.113$ （点划线）。对应地，将 $[0, 0.113]$ 设定为“判正常区”， $(0.113, 0.124)$ 为“灰区”， $[0.124, 1]$ 则为“判异常区”。

从密度分布来看，绝大多数正常样本集中在左侧低概率区域，而异常样本则明显右偏，分布范围更广，表明该方法能在控制漏诊率与误报率的前提下较好地区分两类样本。灰区设置也有助于避免模型对边界样本做出不确定性过高的决策，增强了预测的可靠性与解释性。

2. 验证结果

除可判定样本的混淆矩阵外，本文进一步统计了模型在校准集上的关键评估指标、错误率及不确定性得分，并提取特征重要性排名结果，以全面呈现最终判别模型的性能表现与依赖变量特征，如下表：

表 8: 模型评估指标与特征重要性

评估指标	数值	特征名称	重要性得分
召回率 (cal_recall)	1.0000	X染色体浓度	0.3320
特异度 (cal_spec)	0.0625	孕妇BMI	0.1008
精度 (cal_prec)	0.1429	GC含量	0.0746
F1 分数 (cal_F1)	0.2500	d21_gc	0.0645
可判定性分数 (cal_U)	0.6754	21号染色体的Z值	0.0623
异常样本误判率 (cal_err_pos)	0.2632	Z21.2项交互项	0.0503
正常样本误判率 (cal_err_neg)	0.0000	重复读段的比例	0.0458
异常样本置信度均值 (q_pos)	0.9683	原始读段数	0.0414
正常样本置信度均值 (q_neg)	0.1188	GC差异比值	0.0391
可判定样本数 (cal_n)	114	d18_gc	0.0384

可见，模型在可判定子集上实现了 100% 的异常检出率与 0% 的漏判率，异常被误判为正常的频率为 0.000，正常被误判为异常的频率为 0.263，均满足设定误差上限。尽管正常样本特异度仅为 6.25%，但整体可判定性得分 $U = 0.6754$ ，表明模型敏感度非常高，异常胎儿一定会被识别出来。可判定样本中精确率为 0.143，F1 值为 0.250，平均精度（AP）为 0.269，较逻辑回归基线 0.11 明显提升。变量重要性方面， Z_X 、孕妇 BMI 与 GC 含量得分居前三（分别为 0.3320、0.1008 与 0.0746），其后包括 Z_{21} 、GC 偏移与重复率等，均与生物学机制高度一致，佐证了变量构建的合理性。可见特征中，21号染色体Z值和孕妇BMI最关键，整体适合用于严格排查高风险样本。

为进一步评估模型在正负样本极度不均衡情境下的分类性能，图 23 展示了校准集上的 Precision-Recall 曲线及其对应的平均精度（AP）指标。




图 23: 校准集 Precision-Recall 曲线 ($AP = 0.269$)

从图中可以看出，模型在低 Recall 区域（约 $0 \sim 0.2$ ）表现出较高的 Precision（最高达 1.0），说明其在初步识别高置信异常样本时具有较强的判别力。但随着 Recall 的提高，Precision 呈现震荡式下降，最终趋于随机水平。平均精度（AP）为 0.269，显著高于随机基线 0.075，表明模型整体上优于随机猜测，风险识别能力较好。

然而，PR 曲线并未呈现单调下降的理想形态，表明模型在部分阈值下存在判别能力波动，可能受限于特征间冗余或训练集异质性。此外，我们绘制其真实标签与预测标签的混淆矩阵，如图：




图 24: 校准集可判定内混淆矩阵，可判定占比为 0.308

可见，在被模型明确判别的 37 个样本中（占全体样本的 30.8%），预测结果与真实标签高度一致。所有 5 个实际为异常的样本均被正确识别，异常检出率（召回率）达到了 100%，同时未出现任何假阴性（ $FN = 0$ ），体现出模型对高风险个体的极强识别能力。正常样本中，仅有 6%（即 2 例）被误判为异常，误警率控制在较低水平。

至此，该双模型结构在满足题意约束条件下，实现了对女胎异常样本的识别水平，并在控制误判、解释模型结果和适应不同数据的能力方面也表现得比较均衡和理想。

九、模型评价

9.1 模型亮点

- 双重误差控制

在问题四中，结合 EasyEnsemble 欠采样结构与校准过程的双模型策略，在异常样本识别上取得较高召回率的同时，显著降低了正常样本的误判率，兼顾异常样本的高识别率与正常样本的低误判率，全面提升模型的判别性能。

- 判别机制清晰

模型输出明确的样本预测概率与关键特征重要性，有助于理解模型判别依据，支持后续改进，如调整 GC 控制区间、进一步筛选染色体特异性指标等，提升临床可用性。

- 特征构建合理

在问题四中，模型引入孕妇 BMI、GC 含量偏移、测序重复率等信息，并构建如 $Z_{\max}$ 、 Z^2 、交互项等派生变量，实现多源特征融合与非线性结构刻画。相比传统仅基于 Z 值打分的方法，模型对异常信号更敏感，判别能力显著增强。

- 结果输出清晰可解释

在问题四中，模型训练完成后输出了校准集上的混淆矩阵、AUC、灵敏度、特异度、F1 值等一系列关键评估指标，并进一步分解误判结构，结合特征重要性排序与不确定性得分分析，识别边缘样本与核心判别特征。提高模型在临床应用中的透明度,辅助实际风险筛查决策。

9.2 模型不足

- 未考虑流产事件

本文在问题一至问题四的建模与分析中未考虑妊娠中止情况。如果部分孕妇在到达理论最优检测孕周之前已经流产，那么模型预测的检测时点在实际中可能无法实现。这会使晚孕周的检测成功率被高估，从而导致结果偏于乐观，低估了部分孕妇面临的真实风险。而已有研究表明，特定人群（如 IVF 孕妇）的妊娠结局与游离 DNA 表现存在差异 [3]，进一步说明流产因素对模型适用性不可忽视。

- 检测失败与质控样本剔除

本文未考虑测序失败或质控未通过样本的情况，也未分析其与孕周或 BMI 的关系。如果这些样本在分析中被系统性地剔除，就可能导致结果偏向成功样本，从而高估模型的效果。

- 第四问模型存在误伤率偏高问题

在第四问的异常胎识别中，采用 EasyEnsemble + Logistic 回归方法，通过欠采样构建集成学习模型，并以置信度分数作为后续筛选的依据。虽然该方法实现了对异常胎的高召回率（100%），但模型的特异度较低，仅为 6.25%，意味着部分的正常胎儿被误判为异常。在实际应用中有必要引入代价敏感学习或不平衡自适应算法进一步优化误伤控制。

十、参考文献

- [1] 国汐如, 吕瑾莪, 苏涛, 等. 母亲孕前体质量指数和孕早期血脂与学龄前儿童超重肥胖风险的关联[J/OL]. 中国学校卫生, 1-5 [2025-09-07]. <https://doi.org/10.16835/j.cnki.1000-9817.2025239>.
- [2] 张亮亮, 卓召振, 黄盛文, 等. 贵州省多中心16798例NIPT-plus结果回顾性分析[J]. 贵州医药, 2025, 49(08):1296-1299.
- [3] 岑妙兰. NIPT在IVF孕妇群体产前筛查中的应用研究[D]. 华南理工大学, 2020. DOI:10.27151/d.cnki.ghnlu.2020.001678.

十一、附录

预处理

```
# 路径
in_path = r"C:\Users\MSI_NB\Desktop\数学建模\附件.xlsx"
out_path = r"C:\Users\MSI_NB\Desktop\数学建模\附件_清洗完成.xlsx"

# 工具: 日期转标准年月日
def parse_date(x):
    if pd.isna(x):
        return pd.NaT
    s = str(x).strip()
    if s.isdigit() and len(s) == 8: # 例: 20240126
        return pd.to_datetime(s, format="%Y%m%d", errors="coerce")
    return pd.to_datetime(x, errors="coerce")

# 工具: 把\检测孕周"的各种写法转为小数周
def parse_gw_to_float(v):
    if pd.isna(v):
        return np.nan
    s = str(v).strip()
    try:
        return float(s) # 已经是数就直接用
```

```

except Exception:
    pass
s_norm = s.replace(" ", "").lower().replace("周", "w").replace("天", "")
m = re.fullmatch(r'(\d+)(?:w)?(?:\+(\d+))?$', s_norm) # 12w+5 / 12+5
if m:
    w = int(m.group(1))
    d = int(m.group(2)) if m.group(2) is not None else 0
    return w + d / 7.0
m2 = re.fullmatch(r'(\d+)w$', s_norm) # 12w
if m2:
    return float(m2.group(1))
return np.nan

# 工具: 把日期列渲染成 yyyy-mm-dd 文本
def format_date_columns_to_text(df, cols=("末次月经", "检测日期")):
    for c in cols:
        if c in df.columns:
            df[c] = pd.to_datetime(df[c], errors="coerce").dt.strftime("%Y-%m-%d")
    return df

# 工具: IVF妊娠映射到 0/1/2 (自然/IVF/IUI), 其余保留原值
def map_ivf_series(s):
    mapping = {"自然受孕": 0, "IVF (试管婴儿)": 1, "IUI (人工授精)": 2}
    out = s.copy()
    mask_str = out.apply(lambda x: isinstance(x, str))
    out.loc[mask_str] = out.loc[mask_str].map(mapping).fillna(out.loc[mask_str])
    return out

# 工具: 胎儿是否健康 映射到 0/1 (健康=0, 不健康=1), 其余保留
def map_health_series(s):
    mapping = {"健康": 0, "不健康": 1, "是": 0, "否": 1}
    out = s.copy()
    mask_str = out.apply(lambda x: isinstance(x, str))
    out.loc[mask_str] = out.loc[mask_str].map(mapping).fillna(out.loc[mask_str])
    return out

# 单表清洗

```

```
def correct_sheet(df):
    df = df.copy()

    # 日期
    if "末次月经" not in df.columns or "检测日期" not in df.columns:
        return df
    ...
```

问题1（改版）

```
# 读 Excel
df0 <- read_excel("E:/数学建模2025/附件数据清洗3.xlsx", sheet = 1)

# 重命名与预处理
df <- df0 %>%
  rename(
    id_sample = 序号,
    id_mother = 孕妇代码,
    age = 年龄,
    height = 身高,
    weight = 体重,
    gestw = 检测孕周,
    bmi = 孕妇BMI,
    y_frac = Y染色体浓度,
    aneuploid = '染色体的非整倍体(空白为0, 非空白为1)'
  ) %>%
  mutate(
    ivf = factor(ivf, levels = c(0,1,2), labels = c("natural","IVF","IUI")),
    conception = fct_collapse(ivf, natural="natural", ART=c("IVF","IUI")),
    parity = as.integer(delivery_n),
    test_date = as_date(test_date),
    batch = format(test_date, "%Y-%m")
  ) %>%
  filter(aneuploid == 0 | is.na(aneuploid))
```

由于代码很多，这里仅展示了最核心的部分，完整代码见论文附件。

问题2

```
from matplotlib import font_manager as fm

def setup_zh_font(prefer=("Microsoft YaHei","SimHei","SimSun","Noto Sans CJK SC","Source Han Sans C
    installed = {f.name for f in fm.fontManager.ttflist}
    for fam in prefer:
        if fam in installed:
            matplotlib.rcParams["font.family"] = fam
            matplotlib.rcParams["axes.unicode_minus"] = False
            matplotlib.rcParams["pdf.fonttype"] = 42
            matplotlib.rcParams["ps.fonttype"] = 42
            print(f"[OK] 使用字体: {fam}")
            return
    candidates = [r"C:\Windows\Fonts\msyh.ttc", r"C:\Windows\Fonts\simhei.ttf", r"C:\Windows\Fonts\
    for p in candidates:
        if os.path.exists(p):
            fm.fontManager.addfont(p)
            fam = fm.FontProperties(fname=p).get_name()
            matplotlib.rcParams["font.family"] = fam
            matplotlib.rcParams["axes.unicode_minus"] = False
            matplotlib.rcParams["pdf.fonttype"] = 42
            matplotlib.rcParams["ps.fonttype"] = 42
            print(f"[OK] 添加字体文件: {p} -> {fam}")
            return
    print("[WARN] 未找到中文字体")

setup_zh_font()

# 读表
def safe_read_excel(candidates=None, sheet_candidates=None, engine="openpyxl"):
    cand = (candidates or []) + [r"附件_清洗完成.xlsx", r"附件数据清洗3.xlsx"]
    cand += glob.glob("**/附件_清洗完成.xlsx", recursive=True)
    cand += glob.glob("**/附件数据清洗3.xlsx", recursive=True)
    fpath = None
    for p in cand:
```

```

        if p and os.path.exists(p):
            fpath = p; break
    if fpath is None:
        raise FileNotFoundError("未找到数据文件")
    xls = pd.ExcelFile(fpath, engine=engine)
    pick = xls.sheet_names[0]
    print(f"[OK] 读取: {os.path.abspath(fpath)} | Sheet: {pick}")
    return pd.read_excel(fpath, sheet_name=pick)

# 找列
def find_col(cols, keys):
    cols = [str(c).strip() for c in cols]
    for k in keys:
        for c in cols:
            if k in c:
                return c
    return None

```

问题3

#读取与清洗（仅按总GC过滤）

基本配置

```

FILE_PATH    = r"C:\Users\MSI_NB\Desktop\数学建模\附件_清洗完成.xlsx"
SHEET_NAME   = 0
THR_RAW      = 0.04
ASSAY_CV_BASE = 0.10
RANDOM_STATE  = 42

```

工具函数

```

def _find_col(cols, keys):
    cols_ns = [str(c).strip().replace(" ", "") for c in cols]
    for k in keys:
        k = str(k).strip().replace(" ", "")
        for i,c in enumerate(cols_ns):
            if k in c: return cols[i]
    return None

```

```

def _parse_week(x):
    if pd.isna(x): return np.nan
    s = str(x).strip()
    m = re.match(r"^s*(\d+)\s*\+\s*(\d+)\s*/\s*\d+\s*$", s) # 12+3/7
    if m: return int(m.group(1)) + int(m.group(2))/7.0
    m = re.findall(r"(\d+)\s*(?:周|w|W)?\s*\+\s*(\d+)?", s) # 12周+3 / 12+3
    if m:
        w = int(m[0][0]); d = int(m[0][1]) if m[0][1] not in [None,""] else 0
        if "+" in s or "周" in s or "w" in s.lower(): return w + d/7.0
    try: return float(s)
    except: return np.nan

# 读取表格
raw = pd.read_excel(FILE_PATH, sheet_name=SHEET_NAME)
cols = list(raw.columns)

# 列名
col_age = _find_col(cols, ["孕妇年龄", "年龄", "C"])
col_ht = _find_col(cols, ["孕妇身高", "身高", "D"])
col_wt = _find_col(cols, ["孕妇体重", "体重", "E"])
col_ga = _find_col(cols, ["孕妇本次检测时的孕周", "孕周", "J"])
col_bmi = _find_col(cols, ["孕妇BMI指标", "BMI", "K"])
col_yconc = _find_col(cols, ["Y染色体浓度", "Y浓度", "V"])
col_gc = _find_col(cols, ["GC含量, 序列中碱基", "GC含量", "P"])
col_reads_total = _find_col(cols, ["原始测序数据的总读段数", "总读段数", "L"])
col_map_rate = _find_col(cols, ["在参考基因组上比对的比例", "比对的比例", "M"])
col_dup_rate = _find_col(cols, ["重复读段的比例", "N"])
col_uniq_reads = _find_col(cols, ["唯一比对的读段数", "O"])
col_filtered = _find_col(cols, ["被过滤掉的读段数占总读段数的比例", "AA"])

need = [col_ga, col_bmi, col_yconc, col_gc]
assert all(need), "缺少必须列（孕周/BMI/Y浓度/GC总）"

# 基础清洗
df = raw.copy()
df[col_ga] = df[col_ga].apply(_parse_week)

```

```
for c in [col_bmi,col_age,col_ht,col_wt,col_yconc,col_gc,
          col_reads_total,col_map_rate,col_dup_rate,col_uniq_reads,col_filtered]:
```

问题4

```
# 路线B: 增强特征 + EasyEnsemble + 共形预测 (一次收敛)
# 数据: E:\数学建模2025\附件数据清洗3.xlsx / sheet='女胎检测数据'
```

```
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import GroupShuffleSplit
from sklearn.calibration import CalibratedClassifierCV
from sklearn.metrics import (confusion_matrix, roc_auc_score, average_precision_score)
from sklearn.inspection import permutation_importance
```

```
from imblearn.ensemble import EasyEnsembleClassifier
```

```
# 配置
```

```
FILE_PATH = r"E:\数学建模2025\附件数据清洗3.xlsx"
```

```
SHEET_NAME = "女胎检测数据"
```

```
RANDOM_STATE = 2025
```

```
EPS_POS_INIT = 0.05
```

```
EPS_NEG_GRID = [0.15, 0.20, 0.25, 0.30]
```

```
QC_MIN_QUANTILE = 0.10
```

```
# 列名映射
```

```
M = {
```

```
    "id": "孕妇代码", "age": "年龄", "gest": "检测孕周", "BMI": "孕妇BMI",
```

```
    "reads": "原始读段数", "map": "在参考基因组上比对的比例", "dup": "重复读段的比例",
```

```
    "uniq": "唯一比对的读段数", "filt": "被过滤掉读段数的比例", "GC": "GC含量",
```

```
    "Z13": "13号染色体的Z值", "Z18": "18号染色体的Z值", "Z21": "21号染色体的Z值", "ZX": "X染色体的Z值",
```

```
    "y13": "T13", "y18": "T18", "y21": "T21",
```

```
    "GC13_chr": "13号染色体的GC含量",
```

```
    "GC18_chr": "18号染色体的GC含量",
```

```
    "GC21_chr": "21号染色体的GC含量",
```

```

    "Xconc": "X染色体浓度",
}

# 小工具
def zscore(s: pd.Series):
    m, sd = s.mean(), s.std(ddof=0)
    return (s - m) / sd if (sd and not np.isnan(sd)) else pd.Series(0.0, index=s.index)

def conformal_q(a: np.ndarray, eps: float):
    a = np.sort(a[~np.isnan(a)])
    if a.size == 0: return np.inf
    k = ceil((a.size + 1) * (1 - eps))
    k = min(max(k, 1), a.size)
    return a[k-1]

def metrics_from_cm(cm):
    tn, fp, fn, tp = cm[0,0], cm[0,1], cm[1,0], cm[1,1]
    sens = tp/(tp+fn) if (tp+fn)>0 else np.nan
    spec = tn/(tn+fp) if (tn+fp)>0 else np.nan
    prec = tp/(tp+fp) if (tp+fp)>0 else np.nan
    f1 = 2*prec*sens/(prec+sens) if (prec+sens)>0 else np.nan
    return sens, spec, prec, f1

# 读取 & 预处理 (保留\检测孕周"原始字符串)
df = pd.read_excel(FILE_PATH, sheet_name=SHEET_NAME)

# 数值化
num_cols = [c for c in [
    M["age"], M["BMI"], M["reads"], M["map"], M["dup"], M["uniq"], M["filt"], M["GC"],
    M["Z13"], M["Z18"], M["Z21"], M["ZX"],
    M["GC13_chr"], M["GC18_chr"], M["GC21_chr"]
] if c in df.columns]

for c in num_cols:
    df[c] = pd.to_numeric(df[c], errors="coerce")

# 构造特征
feat_cols = []

```

```

if all(c in df.columns for c in [M["Z13"],M["Z18"],M["Z21"]]):
    df["Zmax"] = df[[M["Z13"],M["Z18"],M["Z21"]]].max(axis=1)
    df["Zsum"] = df[[M["Z13"],M["Z18"],M["Z21"]]].sum(axis=1)
    feat_cols += ["Zmax","Zsum"]

if M["ZX"] in df.columns and M["BMI"] in df.columns:
    df["ZXxBMI"] = df[M["ZX"]] * df[M["BMI"]]
    feat_cols.append("ZXxBMI")

if "Zmax" in df and "QC" in df.columns:
    df["ZmaxxQC"] = df["Zmax"] * df["QC"]
    feat_cols.append("ZmaxxQC")

# 标准化
scaler = StandardScaler()
X = scaler.fit_transform(df[num_cols + feat_cols].fillna(0))

# 标签: ANY
y_any = ((df[M["y13"]]==1) | (df[M["y18"]]==1) | (df[M["y21"]]==1)).astype(int).values

# 分组划分 (按个体ID分组打乱)
gss = GroupShuffleSplit(n_splits=1, test_size=0.3, random_state=RANDOM_STATE)
groups = df[M["id"]].astype(str).values if M["id"] in df.columns else np.arange(len(df))
tr_idx, te_idx = next(gss.split(X, y_any, groups))

X_tr, X_te = X[tr_idx], X[te_idx]
y_tr, y_te = y_any[tr_idx], y_any[te_idx]

# 训练分类器 + 概率校准
base = EasyEnsembleClassifier(
    n_estimators=10,
    random_state=RANDOM_STATE
)
clf = CalibratedClassifierCV(base, method="isotonic", cv=3)
clf.fit(X_tr, y_tr)

# 训练集\保留法"非符合度分数 (共形预测所需)
proba_tr = clf.predict_proba(X_tr)[: , 1]

```

```

alpha_pos = 1 - proba_tr[y_tr == 1] # 阳性类非符合度
alpha_neg = proba_tr[y_tr == 0]     # 阴性类非符合度

# 测试集概率
proba_te = clf.predict_proba(X_te)[: , 1]

# 共形预测阈值
q_pos = conformal_q(alpha_pos, EPS_POS_INIT)
print("q_pos =", q_pos)

for eps_neg in EPS_NEG_GRID:
    q_neg = conformal_q(alpha_neg, eps_neg)
    y_pred = []
    for p in proba_te:
        if p < q_neg:
            y_pred.append(0)
        elif p > 1 - q_pos:
            y_pred.append(1)
        else:
            y_pred.append(2) # 灰区
    y_pred = np.array(y_pred)

    cm = confusion_matrix(y_te[y_pred != 2], y_pred[y_pred != 2])
    sens, spec, prec, f1 = metrics_from_cm(cm)
    print(f"eps_neg={eps_neg:.2f} | sens={sens:.3f} | spec={spec:.3f} | prec={prec:.3f} | f1={f1:.3f}")

```

由于代码过长, 剩余部分见附件

四个模型 REML 对比图

```

# 四个模型 REML 对比图
# 模型对比结果 (示例)
mods = ["m1", "m2", "m3", "m4"]
remls = [1234.5, 1220.3, 1188.9, 1195.7]

plt.figure(figsize=(6,4))
plt.bar(mods, remls, color="skyblue")
plt.ylabel("REML")

```

```
plt.title("四个模型 REML 对比图")  
plt.show()
```

由于代码较长，这里仅展示了绘图的核心部分，完整实现见附件。